Teacher Scoring 的 FSDP2 执行架构

真实 Worker ·单 GPU ·完整评分契约

请求输入

`input_ids` / attention mask

Student 候选 ID [batch, T, K]

TeacherFSDPWorker

prepare_model_inputs / layout 对齐

校验候选、mask 与 offsets

执行策略

Chunk rows B / 读出预算 H

选择 Dense 或 Chunked；不符合预算时拒绝

Qwen2 / FSDP2 的单次外层 forward

共享 LM Head 参数·模块 hooks ·CPU offload（可选）

Transformer Backbone + Final RMSNorm

Hidden states $\mathbf{H} \in \mathbb{R}^{N \times d}$

同一请求只选择一条路径

A0 原生 Dense 路径

LM Head：$\mathbf{HW}^{\mathsf{T}}$

物化完整 Logits $[N, V]$

完整张量返回 FSDP forward 之外

A1 显存受控路径

逐块 $\mathbf{H}_i[B, d] \rightarrow$ LMHead $\rightarrow \mathbf{Z}_i[B, V]$

逐块 FP32 LSE / 候选 Gather / Teacher Top-K

写入紧凑缓冲区 $[N, K]$；释放 $\mathbf{Z}_i$，处理下一块

$\lceil N/B \rceil$ LM-head calls, 有界临时张量

FSDP forward 返回后的归约

全词表 LSE / Gather / Top-K

已完成逐块归约

仅返回紧凑结果；不拼接完整 Logits

相同的 Worker 输出契约

候选 logprob $[N, K]$；Teacher Top-K ID $[N, K]$

按有效行恢复 CPU Nested Tensor 与 offsets

独立验证：固定 Reverse-KL Loss → Student 梯度 → 受限 RMSNorm 更新

符号：N 为投影行数，V 为词表大小，B 为行块大小；预算只估算 LM Head 读出内存。