LM Head 的中间张量生命周期

相同的评分契约，不同的峰值分配方式

A0 Dense　　完整读出：先构建全部 $N \times V$ Logits，再归约。

$\mathbf{H}[N, d] \longrightarrow$ LMHead $\longrightarrow \mathbf{Z}[N, V]$



[N,V] 临时张量在归约期间存活

A1 Chunked　　逐块读出：分块计算并归约，每次只保留 $B \times V$ Logits。

$\mathbf{H}_i[B, d] \longrightarrow$ LMHead $\longrightarrow \mathbf{Z}_i[B, V]$



逐块：LSE / Gather / Top-K → 写入 $[N, K]$ → 释放 $\mathbf{Z}_i$

完整 Logits 临时空间：$O(NV)$　　分块临时空间：$O(BV)$；紧凑结果 $O(NK)$

已测（N=8192，K=32，B=256）：PyTorch peak allocated 3596.6 → 681.6 MiB（−81.05%）

Transformer 隐状态、模型参数、FSDP 缓冲区及 workspace 均不包含在以上简化临时空间表达式中。