显存预算约束的
Teacher Scoring

保留完整契约的 FSDP 接入、分配器容量与真实 Worker-to-Student 证据

作者	Jiacheng Yu
版本	2026 年 10 月 30 日；简体中文
文稿状态	AI 辅助技术草稿；所有新增内容等待 Human 审核
证据快照	基线 `0fd56a6` 与其后的 Worker 和 mask 验证
已验证范围	单 GPU Qwen2/FSDP2；有界数值、容量与受限更新实验

审核边界。本文是新报告，不继承旧 `c1ab1f4` 中英文报告的作者审核状态。旧报告及 10 月 30 日 Markdown/PDF 增补继续作为独立快照保留。第 10 节记录后续有界 Worker 与 mask 验证及其测量范围。

显存测量随 allocator 与执行范围报告。行分块已有先例；本文不声明新的 selected-logit 内核或普遍时延收益。

摘要

Teacher 即使只返回紧凑分数，也可能先分配完整 token×vocabulary logits。本实现把行分块前移到 Qwen2 LM Head 之前，保留 Student 候选 ID 上的全词表归一化 logprob 和 Teacher 自身 Top-K。适配器在普通外层 FSDP forward 内运行，保留模块 hooks 与共享参数；无显式预算且分块覆盖全部投影行时，使用原生 dense forward 回退。受控单 GPU 实验完成 384 次直接模型调用及 64 次真实 Worker 调用，没有复现先前 CUDA abort。在 PyTorch allocator fraction 0.25 下，offload 开启的 dense 路径在 1536 行成功、2048 行 OOM，chunked 执行到 32768 行，但同长度 dense 数值校验只到 8192。fraction 0.50 下，dense 在 8704 成功、9216 失败；更高预算的 dense 参考验证了 chunked 的 9216 行输出。真实 Worker 输出还保留了固定 loss、所检梯度和一次最终 RMSNorm AdamW 更新。后续真实 Worker 在 8192 行与同预算 Dense 一致，在 9216 行与较高预算 Dense 参考一致。无人工 fraction 的 1024 行实验测量显存，并未测容量上限；完整 RL 训练和 Ray 调度仍未覆盖。

目录

1 问题动机与贡献边界 **2**

2 完整评分与消费契约 **2**

3 FSDP 执行与受限读出 **3**

3.1 模块与 hooks 生命周期 3

3.2 CPU offload 与 dense fallback 4

3.3 预算估计及约束范围 4

4 实验设计与执行身份 **4**

4.1 Worker 对齐的 buffer 构建 5

5 S1：受控稳定性 **5**

6 明确 allocator fraction 下的容量 **5**

7 M1 与 T1：显存口径和描述性时延 **6**

7.1 Allocator 峰值与整设备观察 6

7.2 Worker 对齐的完整 forward 配对时延 6

8 I1：真实 Worker 输出进入受限 Student 更新 **6**

9 负结果与证据解释 **7**

10 真实长序列 Worker、自然分配与 response mask 验证 **7**

11 复现入口与技术判断 **8**

1 问题动机与贡献边界

蒸馏消费者所需的信息不同：指定 logits、条件概率、全词表 logprob 和 Teacher Top-K 是不同契约。返回 NK 个数值的接口，内部仍可能执行和分配 NV 投影。其中 N 为实际经过 Head 的模型行数，V 为词表大小，K 为候选宽度；padding 行也计入 N。

逐行评分接口与索引 selected-logit 原语已经处理其中部分问题。此前源码调查记录了相关 SGLang、vLLM 接口及 IndexedLogits，这些观察仍限定在当时的固定版本。[1, 3, 5, 7] 本报告的工程对象更具体：在固定 verl 的 Qwen2/FSDP 执行中，限制 logits tile 的分配，同时保留完整 Teacher 契约。行分块是已有方法；此前仅计算 Student 候选 logits 的融合方案，对完整契约仍为 **NO-GO**。

目标为 verl PR #6920 的固定版本 `87cd055e872f9fdd7b976fcd797a0934b6dba265`。补丁显式启用，关闭时保留上游分支。源码观察及本地运行不代表上游已接受或合并。

2 完整评分与消费契约

对第 t 行，隐状态为 h_t，输出头权重为 W、bias 为 b，候选支持集为 C_t：

$$z_{t,i} = h_t^{\mathsf{T}} W_i + b_i, \tag{1}$$

$$\ell^{\text{full}}_{t,i} = z_{t,i} - \mathrm{LSE}_{j\in\mathcal{V}}\, z_{t,j}, \tag{2}$$

$$\ell^{C}_{t,i} = z_{t,i} - \mathrm{LSE}_{j\in C_t}\, z_{t,j} = \ell^{\text{full}}_{t,i} - \log Q_t(C_t). \tag{3}$$

返回值是 $\ell^{\text{full}}_{t,i}$，而非 $\ell^{C}_{t,i}$；另一输出是 Teacher 对整个词表的 Top-K。通常不能从选中 logits 重建全词表归一化分母，也无法据此确定 Teacher Top-K。因此，只投影 Student 候选不能替换当前两字段接口。

上述公式中的 C_t 表示数学支持集。实际接口承载 $[B, T, K]$ 形状的有序 int64 ID，允许重复 ID；gather 后的分数必须保留其顺序与重复次数。候选 ID 已经指向因果 logits 行，适配器不额外位移，也不改变温度。

修改后的 Worker 仍只返回 `teacher_on_student_logp` 与 `teacher_topk_ids`，为 detached CPU nested tensors，保持原有效行顺序及 offsets。候选使用实际 prepared attention mask 散射至 padded 行，再用同一 mask 还原。多序列 padded 输入在此布局路径内支持；多序列 packed/remove-padding 注意力，在真实 varlen 执行验证前明确拒绝。

作为目标区别的数学背景，固定支持集上的条件反向 KL 为：

$$p_i^C = \frac{e^{z_i^S/\tau_S}}{\sum_{j\in C} e^{z_j^S/\tau_S}}, \qquad q_i^C = \frac{e^{z_i^T/\tau_T}}{\sum_{j\in C} e^{z_j^T/\tau_T}}, \tag{4}$$

$$L_C = \sum_{i\in C} p_i^C \log \frac{p_i^C}{q_i^C}, \tag{5}$$

$$\frac{\partial L_C}{\partial z_j^S} = \frac{p_j^C}{\tau_S}\left(\log \frac{p_j^C}{q_j^C} - L_C\right), \quad j \in C. \tag{6}$$

它说明条件重归一化后共同全词表分母会相消，并不表示所有 OPD loss、clamp 和 mask 都等价。条件 KL 忽略支持集总质量差异及尾部分布：

$$D_{\mathrm{KL}}(P\|Q) = D_{\mathrm{Ber}}(\alpha\|\beta) + \alpha D_{\mathrm{KL}}(P^C\|Q^C) + (1-\alpha) D_{\mathrm{KL}}(P^{\bar{C}}\|Q^{\bar{C}}). \tag{7}$$

第 8 节实际调用固定 `compute_reverse_kl_topk` 源码，保留其归一化与 clamps，没有用上述简式替换真实消费者。此前调查也区分了这一目标与其他 OPD reward 或 subset-loss 构造。[2, 4, 6]

3 FSDP 执行与受限读出

3.1 模块与 hooks 生命周期

适配器在 FSDP 包装之前安装于普通、未包装的 `Qwen2ForCausalLM`，保留参数对象、模块树及输入输出共享权重。评分请求经 `self.engine.module(...)` 进入普通外层 FSDP forward。Backbone 与最终 norm 执行一次，随后将展平 hidden rows 分块送入 `self.lm_head(tile)`。每块都调用模块本身，使其 pre/post hooks 仍然运行；直接读取权重作矩阵乘法会绕开该生命周期。

每个至多 B 行的 tile 产生 logits，再转为 FP32 做全词表 log-sum-exp 和 candidate gather；logprob 转回 logits dtype，同时保存 Teacher Top-K ID。各块及时释放，不拼接完整 logits。紧凑输出仍占 $O(NK)$；backbone hidden state、模型与 FSDP 分配仍属于完整 forward。

已验证目标为 tied-embedding Qwen2、普通 dense linear head、BF16、world size one、eval/no-grad 与无 KV cache。适配器拒绝不支持的多 rank、untied head、LoRA、量化/QAT、Liger/fused alternative forward 和 sequence parallel。存在 FP32 代码路径不等于已有 FP32 GPU 证据；FSDP1、TP 及多 GPU 仍为 `NOT_RUN`。

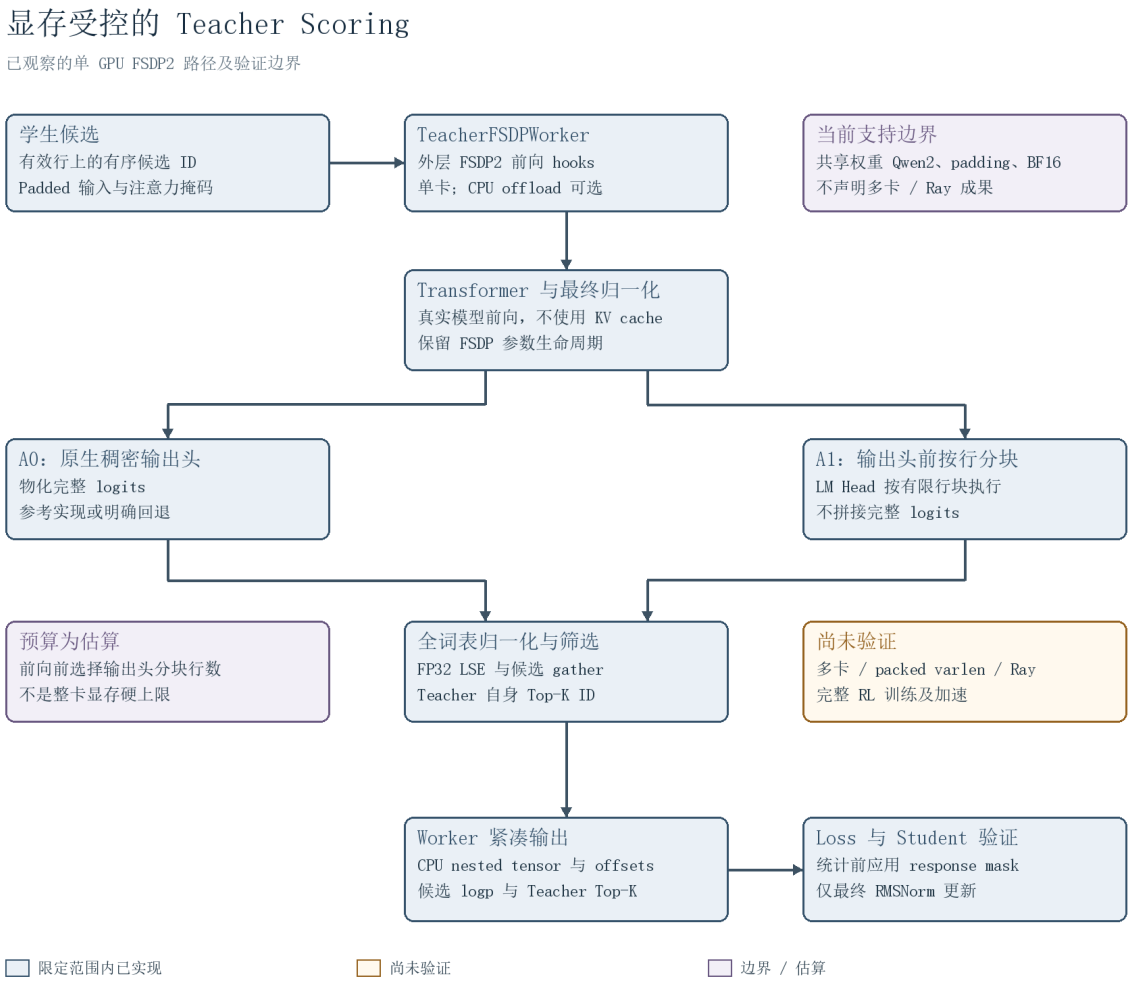


图 1: 显存受限 Teacher 执行与独立的直接 Worker-to-Student 验证路径。数值及运行范围由各实验章节限定；图示不代表尚未执行的调度或训练路径已经通过。

3.2 CPU offload 与 dense fallback

FSDP2 CPU offload 改变参数驻留，且可能主导完整 forward 时延；它不取消普通 FSDP forward 边界。受控实验直接检查 root/decoder 的 offload policy，而非仅根据命令行开关推断。

没有显式 head budget 且选中 tile 覆盖全部模型行时，走 `dense_full_row_fallback`：先完成原生 dense forward，再在 FSDP 返回后运行原 gather/reduction。若在参数仍驻留时归约完整 tile，峰值反而可能上升；早期 $N = 512$、chunk=512 的全行 tile 使绝对峰值增加约 33.7%，由此形成原生回退策略。任何显式 head budget 都禁用这一自动回退，避免把请求的估计预算默默替换成无界 dense 执行。错误及 OOM 向外传播，不重试外层 forward。

3.3 预算估计及约束范围

令 s 为 logits 每元素字节数，$\gamma = 1.25$ 为默认安全因子，H 为请求的 head 字节预算。实现中的估计为：

$$M_{\text{compact}} = NK(s+8), \tag{8}$$

$$m_{\text{row}} = \lceil \gamma \left[V(s+8) + 24K \right] \rceil, \tag{9}$$

$$\widehat{M}(B) = M_{\text{compact}} + Bm_{\text{row}}, \tag{10}$$

$$B = \min\left(N, B_{\text{requested}}, \left\lfloor \frac{H - M_{\text{compact}}}{m_{\text{row}}} \right\rfloor \right). \tag{11}$$

该式包含紧凑输出、logits tile、最多两个 FP32 词表工作张量及保守 Top-K bookkeeping。若紧凑输出加一行估计都放不下，在 forward 前拒绝。预算只约束该读出估计，不覆盖完整模型、FSDP 参数驻留、碎片、其他进程及所有 CUDA workspace。全词表投影计算量仍约为 $2NVd$；缩小 tile 是分配与更多 Head 调用之间的取舍。

早期独立的 $N = 1024, K = 32$ FSDP2 预算 probe，在 64/128/256 MiB 预算下选出 35/70/141 行；读出 allocated 增量约为 51.03/101.75/204.64 MiB，完整 forward 峰值约 552.28 MiB。它们只校准该工作负载。Head 估计与 `torch.cuda.set_per_process_memory_fraction` 约束的是不同数量。

4 实验设计与执行身份

项目	已记录的固定条件
GPU	NVIDIA RTX 5070 Laptop；8151 MiB
模型	Qwen2.5-0.5B-Instruct；BF16；共享 embedding
模型版本	`7ae557604adf67be50417f59c2c2f167def9a775`
框架	PyTorch 2.14.1+cu130；Transformers 5.19.0
分布式路径	FSDP2，world size one；offload 条件分别记录
输入	合成 tokenized sequences 与固定候选；无采样 RL 轨迹
证据来源	双语 10 月 30 日阶段增补及此前有界适配器记录

表 1: 已记录实验的执行身份。

容量点使用独立新进程、SDPA、$K = 32, B = 256$ 与单条序列；factorial fixture 则为 padded 64/37、$K = 8, B = 16$ 和 eager attention，两者不能混作同一工作负载。输出签名覆盖 shape、dtype、offsets 与 bytes；容量比较检查所有保存的紧凑候选及 Teacher Top-K 集合。若只有紧凑输出，无法证明 full-logits 边界 tie，比较器保留未决 tie/mismatch。

4.1 Worker 对齐的 buffer 构建

最初直接模型与真实 Worker 存在数值构建差异。固定 Worker 显式执行 `model.to(dtype)`，将 Qwen2 rotary frequency buffers 从 FP32 转为 BF16；原直接路径保留 FP32。对齐这一步后，31/32 个 frequency 值改变，所测 fixture 的 808 个候选值及 101 行 Teacher Top-K 恢复逐值一致。它解释这一直接/Worker 输出差异，不解释 CUDA abort。早期直接模型测量仍限定于其原始 buffer 策略。

5 S1：受控稳定性

直接模型 factorial 交叉 Dense/Chunked 与 CPU offload 开/关四种条件，每种三个新进程，每进程两次 warmup 与 30 次计数调用。实际 root/decoder FSDP policies 与请求一致，每次完成调用都核对同一紧凑参考。直接模型进程完成 384 次检查，另两个真实 Worker 进程完成 64 次并核对每次 hash

入口	条件	新进程数	完成调用
直接 Qwen/FSDP2	Dense，offload 开	3	96
直接 Qwen/FSDP2	Chunked，offload 开	3	96
直接 Qwen/FSDP2	Dense，offload 关	3	96
直接 Qwen/FSDP2	Chunked，offload 关	3	96
真实 verl Worker	Dense，offload 开	1	32
真实 verl Worker	Chunked，offload 开	1	32

表 2: 完成次数包含 warmup：每个直接模型条件为 $3(2+30)=96$。

和 offsets。首次 CUDA `unknownerror` 在此有界集合未复现；根因及同期 WSL dxg 观察仍未知。重复运行只证实该有限集合，不能据此认定长期生产稳定性。

6 明确 allocator fraction 下的容量

fraction 0.25 在此设备上对应名义 2,129,510,400 字节 PyTorch 缓存 allocator 限额，不是整设备硬隔离。边界扫描以 512-token 粒度收窄已测区间；成功/OOM 格点不证明单调性或精确最大值。fraction

Fraction	Offload	Dense 成功 / 下一 OOM N	Chunked 最大已测可执行 N	Chunked 的 dense 校验到达 N
0.25	开	1536 / 2048	32768	8192
0.25	关	512 / 1024	16384 / OOM 16896	4096
0.50	开	8704 / 9216	32768	9216

表 3: 已测格点及独立的数值等价边界。

0.25 下，offload 开启组在 $N = 1024, 2048, 4096, 8192$ 通过紧凑比较，关闭组在 $N = 2048, 4096$ 通过，logprob 最大差均为零。更长 Dense 参考使用 fraction 0.55；参考在开启组 $N = 12288$、关闭组 $N = 8192$ OOM。比较器补齐 shape/签名验证后，六组均重新比较并通过，原记录保留。

因此，开启组 8192/1536 是 5.33 倍已观察长度比；32768 仍是无完整同 N Dense 正确性参考的执行容量证据。fraction 0.50 下，Chunked 完成 8192/16384/24576/32768；8192 同预算输出一致，fraction 0.55 的 9216 行 Dense 与 fraction 0.50 Chunked 的 294,912 个候选值及全部 9216 行 Top-K 集合一致。该已验证格点比 Dense 最大已测成功 8704 多 512 tokens（5.88%）。更高预算参考提供正确性证据，不构成同预算容量比较。

7 M1 与 T1：显存口径和描述性时延

7.1 Allocator 峰值与整设备观察

指标，MiB	$N = 1024$，M1		$N = 8192$，fraction 0.50	
	Dense	Chunked	Dense	Chunked
Forward allocated 峰值	1517.09	665.31	3596.83	681.66
含 load/wrap 的进程 allocator 峰值	1517.09	958.48	3596.83	958.48
Forward reserved 峰值	1748	1572	3846	1572
整设备 used 采样最大值	3429	3258	5504	3229
设备采样次数（非 MiB）	40	30	36	33

表 4: Offload 开启的独立新进程比较。100 ms 整设备采样包含其他进程，也可能漏掉瞬时峰值。

较低的调用峰值不代表加载/包装分配消失；reserved 也依赖 allocator 历史。$N = 1024$ 两个采样最大值相差 171 MiB，并非精确净进程 VRAM 收益。fraction 0.50 的 Dense OOM 时，CUDA 仍报告约 3401 MiB 空闲，体现 allocator 限额而非整卡耗尽。本版没有无人工 fraction 的长输入 Worker 容量结果。

7.2 Worker 对齐的完整 forward 配对时延

T1 使用 $N = 1024, K = 32, B = 256$。各 offload 条件含六组 A/A 和八组交错 ABBA/BAAB，每个 A/B 标签 16 个样本。计时覆盖直接模型/FSDP 完整 forward 至紧凑 CPU 副本，排除加载及正确性校验。该口径下 allocated 分别下降 56.17%（开）和 34.52%（关）；候选最大差均为零，全部 1024

Offload	指标	A0 Dense	A1 Chunked
开	Allocated 峰值 MiB	1517.09	664.97
关	Allocated 峰值 MiB	2467.26	1615.48
开	perf-counter p50 / p95 ms	192.580 / 193.953	192.978 / 198.150
开	raw-clock p50 / p95 ms	190.491 / 191.858	190.926 / 196.081
关	perf-counter p50 / p95 ms	87.241 / 114.847	78.709 / 116.953
关	raw-clock p50 / p95 ms	87.567 / 115.198	78.986 / 117.407

表 5: 采用 Worker 对齐 buffer cast 的直接模型配对记录。

行 Teacher Top-K 集合一致。关闭 offload 的进程中，30/32 个 A/B 和 12/12 个 A/A 样本的 CUDA Event 长于包围它的 perf-counter 区间。早期运行也出现主机时钟及实验阶段漂移，原因未解。因此时延只作描述，不声明普遍加速，也不把两个独立 offload 进程当作生产性能排名。

8 I1：真实 Worker 输出进入受限 Student 更新

真实 Qwen Student 生成一次候选，随后两个固定版本的真实 `TeacherFSDPWorker` 顺序执行 Dense 回退与 Chunked。它们当前返回的内存内 CPU nested TensorDict 值散射回原 padded Student 行，直接送入 `compute_reverse_kl_topk`；没有以记录的 JSON Teacher 数值替代。

两条序列的 offsets 为 $[0, 23, 45]$，padded 模型行数为 46，$K = 8$，激活响应预测行数为 25。Student 先按 0.8 温度缩放，再 log-softmax、Top-K；Teacher 温度为 1。候选仍位于原 logits 行，只有 response mask 做 next-token 对齐。两条路径恢复相同最终 RMSNorm 权重和新的 AdamW 状态，学习率 0.01、weight decay 为零。Teacher 保持 detach；保留 support normalization、logprob 下限 -10、token loss 非负截断与最大 loss 截断 10。本 fixture 的 360 个候选值、Teacher Top-K、mass、overlap、token

观察量	Dense Worker	Chunked Worker
Masked scalar loss	0.0216006283	0.0216006283
最终 RMSNorm 梯度 L2	0.0124774044	0.0124774044
非零梯度元素	896	896
改变的 BF16 参数值	1	1
参数更新 L2	0.0099792480	0.0099792480

表 6: 真实 Worker 输出驱动的一次最终 RMSNorm AdamW 更新。

losses、6,989,056 个 Student logits 梯度元素、896 个 RMSNorm 梯度元素及更新结果逐值一致。检查了 outer/head hooks 正常完成、Teacher 无梯度，以及两个顺序 Worker Python 对象均被回收。证据覆盖本地 Worker-to-loss-to-受限更新；Ray 调度、完整 Trainer、全参数优化与 RL step 仍为 `NOT_RUN`。

9 负结果与证据解释

最初 selected-logit 提案不满足全词表归一化加 Teacher Top-K；早期全行 chunk 增加完整峰值，推动了显式原生回退策略。首次 CUDA abort 虽未在受控集合重现，根因仍未知。Buffer cast 解释一个直接/Worker 数值差异，不能用于解释该 abort。

早期项目消费者在两个梯度分支上分别把 BF16 Student logprob 转为 FP32，标量 loss 虽与上游一致，RMSNorm 与 logits 梯度的相对 L2 差异却约为 1.07% 和 1.80%。按上游图结构复用同一次 FP32 转换后，该 fixture 的差异消失。保留这一负结果，是为了说明必须核对梯度和更新，不能只接受标量 loss 一致。

早期样本在 WSL 临时存储清理后丢失，没有重建成历史事实；此处引用后续有记录运行。归档矩阵曾把全行 Head 调用误标为避免完整 logits，实际形状与标签相反，当前脚本已修正。超出 Dense 参考上限的更长 Chunked 结果，数值等价仍为 `UNKNOWN`。退出码或有限输出不替代完整数值及训练验收。

10 真实长序列 Worker、自然分配与 response mask 验证

后续实验均以新进程调用实际固定 `TeacherFSDPWorker`：共享权重 Qwen2 BF16、FSDP2 CPU offload、SDPA、$K = 32$、行块 $B = 256$。文本和候选 ID 为合成输入。每次调用记录实际输入、attention mask、position ID、offset、外层/骨干/输出头 hooks 和完整 CPU nested 输出。长度 64/37 的两个短进程覆盖真实 padding，3232 个候选 logprob 与 101 行有序 Teacher Top-K 均一致。长序列为单条因果序列，不代表长多序列 padding 已获验证。

Worker 条件	Allocated 峰值，MiB		Reserved 峰值，MiB	
	Dense	Chunked	Dense	Chunked
8192，均为 fraction 0.50	3596.638	681.630	3844	866
9216，Dense 0.55 / Chunked 0.50	3893.700	683.962	4144	884
1024，无人工 fraction，A/A 与 B/B	1517.071	665.306	2644	1124

表 7: 独立进程的完整 Worker 调用 allocator 峰值。9216 的 Dense 0.55 只作正确性参考，不构成同预算容量比较。

$N = 8192$ 时，262,144 个候选 logprob 与全部 8192 行有序 Teacher Top-K 完全一致；$N = 9216$ 的跨预算对照中，294,912 个候选及全部 9216 行有序 Top-K 完全一致。每个长序列条件只有一次冷调用，冻结 BF16 容差也通过；两个长度的 offsets 均为 $[0, N]$。这不证明 32768 行相对 Dense 正确，也不代表完整 Trainer 运行。

未调用 `set_per_process_memory_fraction` 的 $N = 1024$ 对照使用 ABBA 顺序的四个新进程，各有一次预热和三次计数调用；每个进程记录的实际 fraction 均为 1.0。A/A、B/B 和 A/B 的紧凑输出及有序 Top-K 一致。Dense 计数样本的 perf-counter 范围为 175.754–200.623 ms，Chunked 为 161.573–191.955 ms；部分样本的主机时钟存在分歧，因此只描述该小样本，不声明加速。100 ms 全设备最大采样分别为 Dense 两进程 4990/5120 MiB、Chunked 两进程 3584/3332 MiB，包含其他进程且可能漏峰。这里没有测试无人工 fraction 的容量上限。

固定 Trainer 的指标包装先按 response 行筛选，再汇总 mass、loss 范围和 overlap；overlap advantage 还要求该行 overlap 大于零。本地诊断采用同一规则并保留原始逐 token 值。CPU 回归将实际固定 Trainer 函数与手算结果比较，并覆盖 prompt/padding 极值或 NaN 和零 overlap；原 Loss 与梯度语义不变。此前 I1 记录的 CPU 重放保留 padding 行 `teacher_mass=8.0`，但在统计中排除它：25 个 response 行的 Teacher mass 均值为 0.732026、最大值为 0.999786。此重放不是新增 GPU 训练步骤。

开始时两次尝试因预登记的空闲显存门槛未满足而为 `NOT_RUN`；一次 CPU 依赖导入失败后，在 GPU 执行前修正了 runner。十个完成的 Worker 进程均记录设备采样无失败。后续 probe 修订在设备观测缺失时将实验标为失败，同时保留已完成的 Worker 输出；实际运行源码及 SHA-256 与原始测量一起保留。该错误处理修正只做 CPU 回归，不改写已记录运行。

11 复现入口与技术判断

源码基线为 `0fd56a618800b5298d8c45529dda675f910c6e47`；后续 Worker probe 与 mask 回归位于包含本报告的版本。原始记录绑定实际测量时所用 probe 的源码字节。固定 loss 为 真实 verl FSDP distillation loss，Git blob 为 `97d3ebf485a5ce9e1b1a435cce427d6d89284dc6`。原始测量附模型与 tokenizer 哈希、命令参数和源码身份。

主要入口包括 `scripts/long_worker_probe.py`、`scripts/factorial_teacher_probe.py`、`scripts/compare_capacity_outputs.py`、`scripts/full_teacher_benchmark.py` 和 `scripts/worker_to_student_step.py`。证据标识包括 `S1_SUMMARY.json`、`capacity_runner.jsonl`、`compare_validated_summary.json`、`compare_on_n9216.json`、`T1_worker_aligned_on/off.json` 与 `worker_to_student_01.json`。前述表格据双语 Markdown 阶段增补转录；上节的新结果来自记录的 Worker 调用与 CPU mask 回归。

可支持的判断是：在所述单 GPU 环境中，保留完整评分契约的受限读出具有实测 allocator 容量收益，并完成了真实受限消费者更新。FP32 GPU、FSDP1、TP/多 GPU、packed varlen、LoRA/量化/QAT、Ray 传输、代表性 RL 轨迹、全模型训练和生产稳定性仍未验证；普遍时延收益、精确整设备 VRAM 节省及训练质量提升未获证实。全部新增正文继续保持 AI 辅助、等待 Human 审核。

参考文献

[1] Jordan Pettyjohn. IndexedLogits: indexed selected-logit CUDA implementation, 2026. URL `https://github.com/pettyjohnjn/indexed_logits/tree/6020cb446cde8cb2b74a8fdf90db905a320936c3`. Source inspected 2026-10-28; no project runtime reproduction.

[2] Jordan Pettyjohn. Subset-KL: subset objective implementation, 2026. URL `https://github.com/pettyjohnjn/subset-kl/tree/69a813ce2233bdf243a39e7d76926ece8af76ed4`. Source inspected 2026-10-28; no project runtime reproduction.

[3] Jordan Pettyjohn, Mansi Sakarvadia, Nathaniel Hudson, Daniel McKenzie, Kyle Chard, and Ian Foster. Interpreting Language Model Hidden States at Scale, 2026. URL `https://arxiv.org/abs/2608.10260v1`. Audited version 2608.10260v1; relevant methods and experimental sections read, not reproduced. Retrieved 2026-10-28.

[4] Rethinking OPD contributors. Current author implementation: rewards and actor update contract, 2026. URL `https://github.com/Thinking-Space/Rethinking-OPD/tree/ac26e38d6f1572eb027597b48a9f4e01f6915ef8`. Source inspected 2026-10-28; no project runtime reproduction.

[5] SGLang contributors. PR 38119: Add sparse per-position requested-token scoring, 2026. URL https://github.com/sgl-project/sglang/pull/38119. Source inspected 2026-10-28; no project runtime reproduction.

[6] verl contributors. Issue 6676: Student-top-k renormalized reverse-KL OPD, 2026. URL https://github.com/verl-project/verl/issues/6676. Source inspected 2026-10-28; no project runtime reproduction.

[7] vLLM contributors. PR 56984: Per-row candidate IDs for prefill token scoring, 2026. URL https://github.com/vllm-project/vllm/pull/56984. Source inspected 2026-10-28; no project runtime reproduction.