显存受控教师评分

基于 FSDP2 的读出路径优化与验证

作者 Jiacheng Yu
实验系统 Qwen2.5-0.5B-Instruct、BF16、单 GPU
执行路径 verl Teacher Worker，FSDP2 与 CPU offload

主要结果。在 8,192 个投影行上，Worker 调用的 peak allocated 从 3,596.6 MiB 降至 681.6 MiB；候选 logprob 和有序教师 Top-K 与稠密参考一致。该内存数据按 PyTorch 分配器口径统计。

摘要

教师评分即使只返回紧凑结果，也可能先生成更大的“投影行 × 词表”logits 张量。本项目将 LM Head 的行分块读出接入固定版本的 verl `TeacherFSDPWorker`，保留学生候选 ID 的全词表归一化 logprob 和教师自身的有序 Top-K，同时经由正常 FSDP2 forward 执行，保留共享权重与模块 hooks。

在单张 RTX 5070 Laptop GPU 上，Qwen2.5-0.5B-Instruct 使用 BF16、$K = 32$、每块 256 行、CPU offload 和 allocator fraction 0.50 时，$N = 8192$ 的 Worker 对照使 peak allocated 降低 81.05%；262,144 个候选分数和 8,192 行有序 Top-K 均逐值一致。独立的直接 Worker 到 Student 实验还匹配了固定损失、所检梯度和一次受限 RMSNorm 更新。该结果属于单 GPU 实验性优化，时延测量用于描述。

目录

1 问题与评分契约 **2**

2 系统架构 **2**

3 实现方法 **3**

3.1 FSDP 与输出头生命周期 3

3.2 分块选择与稠密回退 3

3.3 填充与消费者对齐 3

4 实验设置 **3**

5 实验结果 **3**

5.1 分配器峰值与容量 3

5.2 时延解释 4

6 Worker 到 Student 的验证 **4**

7 当前范围与后续工作 **5**

8 复现 **5**

9 结论 **5**

1 问题与评分契约

令 N 为投影模型行数、V 为词表大小、K 为每行候选数。稠密语言模型输出头即使最终只返回 $O(NK)$ 个值与 ID，也可能先分配 $N \times V$ logits。仅缩小响应并不能限制中间读出分配。

对于隐藏状态行 h_t、输出头权重 W、偏置 b 和候选 i，所需的全词表归一化分数为

$$z_{t,i} = h_t^{\mathsf{T}} W_i + b_i, \qquad \log p_{t,i} = z_{t,i} - \log \sum_{j \in \mathcal{V}} e^{z_{t,j}}. \tag{1}$$

归一化分母覆盖完整词表。Worker 还返回教师自身的有序 Top-K ID，因此仅投影学生候选 logits 通常无法重建完整接口。候选 ID 可以重复，其顺序和重复次数、有效行顺序及嵌套 offset 都属于输出契约。

行分块和 selected-logit 原语均有已有工作；本项目的工程重点是将它们接入固定 Worker、FSDP 生命周期与下游评分契约。[1–3]

2 系统架构

适配器可选启用。Dense 和 Chunked 路径从同一个 Worker 入口执行，并返回相同的紧凑输出；图 1 最后一层表示独立的消费者验证实验。

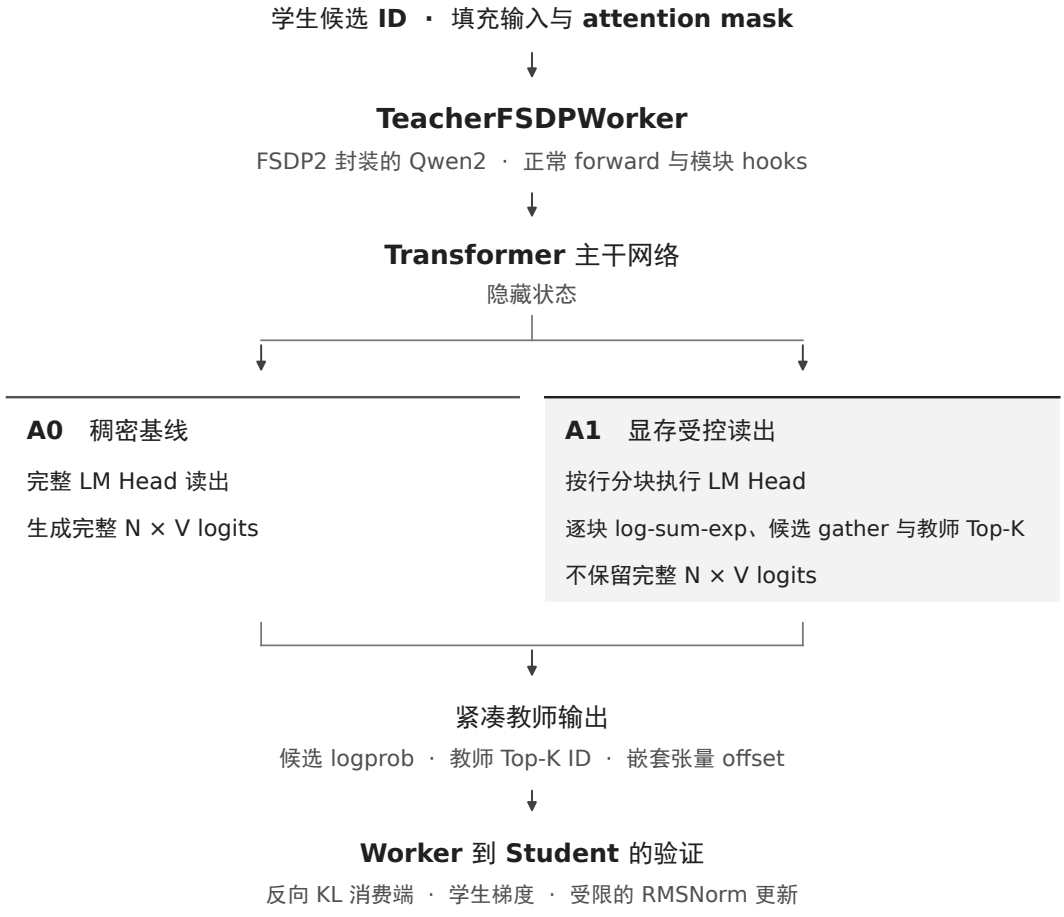


图 1. 教师评分路径与受限的 Worker 到 Student 验证。

3 实现方法

3.1 FSDP 与输出头生命周期

适配器在普通 `Qwen2ForCausalLM` 被 FSDP 封装之前安装，保留参数对象及共享的输入 / 输出权重。请求通过正常的外层 FSDP 模块调用进入；主干网络与最终归一化执行一次，然后将隐藏状态按块送入 `lm_head` 模块。这样既保留输出头的前后 hooks，也保留外层 FSDP forward 边界。

每块 logits 转为 FP32，计算 log-sum-exp 和候选 gather；所选分数转回 logits dtype，并保留教师 Top-K ID。当前块处理完成后丢弃。$B < N$ 时，同时存活的 logits 块随 BV 而非 NV 扩展；紧凑输出仍随 NK 扩展，模型、主干网络和 FSDP 分配依然存在。全词表投影计算并未被消除。

3.2 分块选择与稠密回退

可选的输出头预算在 forward 前确定分块大小。令 s 为 logits 每元素字节数，H 为请求的读出预算，$B_{\text{requested}}$ 为请求的行数上限（省略时取 N），实现中的估算为

$$M_c = NK(s+8), \qquad m_r = \lceil 1.25\,[V(s+8) + 24K] \rceil\,, \tag{2}$$

$$B = \min\left(N, B_{\text{requested}}, \left\lfloor \frac{H - M_c}{m_r} \right\rfloor\right). \tag{3}$$

估算包含紧凑输出、logits 块、FP32 工作张量和 Top-K 开销，不覆盖全部模型分配、后端工作区或内存碎片。未设置显式预算且所选分块覆盖全部行时，集成路径使用原生稠密 forward；显式预算不会被静默替换为这一回退。

3.3 填充与消费者对齐

候选 ID 使用准备好的 attention mask 散射到填充后的模型行，返回时恢复有效行的原始顺序。适配器不对这些 ID 额外施加因果位移。消费者实验在计算聚合损失和诊断指标前，将 response mask 对齐到预测位置。

4 实验设置

最终对照使用 Qwen2.5-0.5B-Instruct、BF16 和 SDPA，运行于单张 RTX 5070 Laptop GPU；软件为 PyTorch 2.14.1+cu130，使用 FSDP2 CPU offload、$K = 32$、$B = 256$ 和 PyTorch allocator fraction 0.50。文本及候选 ID 均为合成数据。每个长度按 Dense–Chunked–Chunked–Dense 顺序运行四个独立进程；每进程预热一次、测量五次。下表中每个模式的 p50/p95 汇总十次测量。

最终矩阵与分块大小实验保存的 96 份紧凑输出均已重新读取，并与同长度 Dense 参考比较。$N = 8192$ 时，262,144 个候选 logprob 和 8,192 行有序教师 Top-K 均逐值一致；比较还检查输出身份、形状和 offset。

5 实验结果

5.1 分配器峰值与容量

表 1 列出逐次 Worker 调用的 PyTorch 峰值和同步耗时。$N = 8192$ 时，peak allocated 从 3,596.6 MiB 降至 681.6 MiB，降幅为 81.05%；reserved 峰值单独列出。该数据不是整设备 VRAM 降幅。

表 1. Worker 调用的分配器峰值与预热耗时。

N	模式	Alloc. MiB	Reserved MiB	p50 ms	p95 ms
1024	Dense	1517.1	2644	210.4	288.0
1024	Chunked	665.3	1124	159.4	187.0
4096	Dense	2409.4	2944	322.3	414.4
4096	Chunked	672.3	1130	318.8	327.5
8192	Dense	3596.6	3846	570.8	599.6
8192	Chunked	681.6	1126	626.3	944.6

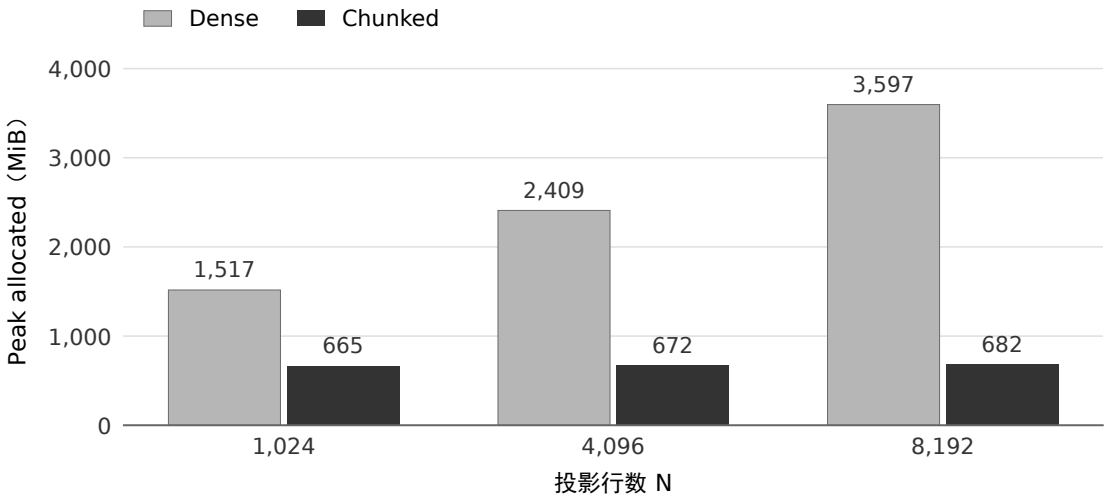


图 2. 表 1 条件下的 peak allocated；柱顶数值按 MiB 取整。

fraction 0.50 下，Dense 在 8,704 行成功、9,216 行达到分配器 OOM；Chunked 在已测最大点 32,768 行运行成功。这些是已测点而非精确容量极限，32,768 行也没有同长度 Dense 正确性参考。

5.2 时延解释

同步耗时包含诊断 hooks 和嵌套输出返回 CPU 的过程。8,192 行时，Dense 的 p50/p95 为 570.8/599.6 ms，Chunked 为 626.3/944.6 ms。小样本中存在进程波动和主机时钟差异，因此这些结果不能支持通用时延收益结论。

6 Worker 到 Student 的验证

在独立的双序列实验中，真实 Dense 和 Chunked Worker 输出直接进入固定版本的反向 KL 消费端。该实验使用 $K = 8$、25 个有效响应预测行，并执行一次仅更新学生最终 RMSNorm 权重的 AdamW 操作。表 2 列出部分观察；所检学生 logits 梯度和最终 RMSNorm 梯度也逐值一致。

表 2. 直接 Worker 到 Student 的验证实验。

指标	Dense	Chunked
掩码后标量损失	0.0216006283	0.0216006283
最终 RMSNorm 梯度 L2	0.0124774044	0.0124774044
发生变化的 BF16 参数值	1	1

早期消费者实现曾出现标量损失一致、所检梯度不同的情况；按照固定消费者复用 FP32 转换后，该实验输入中的差异消失。这也说明验证需要同时比较梯度和更新，而不能只看标量损失。

7 当前范围与后续工作

已测路径覆盖单 GPU FSDP2 下使用共享输出头的 Qwen2；消费者实验是受限参数更新。后续可扩展 packed 变长输入、模型覆盖、FSDP1 与多 GPU / 张量并行验证，并接入端到端 RL Trainer。早期仅计算 selected logits 的融合方案对完整教师契约仍为 NO-GO；历史结果保留了相应负结果。

8 复现

实验评分基线为 `ad395e9`。Worker 补丁基于 verl `87cd055e872f9fdd7b976fcd797a0934b6dba265`，固定 Qwen 模型版本为 `7ae557604adf67be50417f59c2c2f167def9a775`。Linux / Python 3.12 的独立 Worker 锁文件固定了 105 项依赖。复现指南列出环境、模型哈希和命令；证据清单通过 SHA-256 关联归档测量。

展示版本 `c0f019e` 的 GitHub CPU 回归运行报告 171 项通过、2 项取消选择、零跳过。该任务检查 CPU 回归和补丁适用性；GPU Worker 测量是独立实验。

9 结论

将行分块边界前移至 LM Head，使该路径在保留紧凑评分输出的同时降低了读出期间的分配峰值。单 GPU 实测、逐值输出对照和受限 Student 更新，为进一步集成提供了具体依据。

参考文献

[1] Jordan Pettyjohn. IndexedLogits: indexed selected-logit CUDA implementation, 2026. URL `https://github.com/pettyjohnjn/indexed_logits/tree/6020cb446cde8cb2b74a8fdf90db905a320936c3`. Source inspected 2026-10-28; no project runtime reproduction.

[2] SGLang contributors. PR 38119: Add sparse per-position requested-token scoring, 2026. URL `https://github.com/sgl-project/sglang/pull/38119`. Source inspected 2026-10-28; no project runtime reproduction.

[3] verl contributors. Teacher scoring and student-top-K distillation, PR 6920, 2026. URL `https://github.com/verl-project/verl/pull/6920`. Experiments use source revision 87cd055e872f9fdd7b976fcd797a0934b6dba265 and a local project patch; no upstream acceptance is implied.