AI INFRASTRUCTURE / 技术报告

显存受控的教师评分

面向 verl FSDP2 Worker、保留评分契约的输出头读出

Peak allocated 降低 81.05%

在 8,192 个投影行上，完整 Worker 调用的稠密读出为 3,596.6 MiB，分块读出为 681.6 MiB。262,144 个候选 logprob 和 8,192 行有序教师 Top-K 均与稠密参考逐值一致。

作者	Jiacheng Yu
版本	2026 年 10 月 31 日；简体中文
实验系统	Qwen2.5-0.5B-Instruct、BF16、单 GPU、FSDP2 CPU offload
读出条件	$K = 32$、每块 256 行、allocator fraction 0.50
实验基线	`ad395e94923bcf65fff4bc1eeb2e0e1505fd4f91`

该百分比表示完整 Worker 调用中 PyTorch 分配器的 peak allocated，不代表整卡 VRAM 降幅。

摘要

教师评分可能只返回紧凑分数，却仍为全部投影行和词表项生成 logits。本项目在正常 FSDP2 forward 内，将行分块前移至 Qwen2 LM Head 之前。每块计算学生候选 ID 上的全词表归一化分数和教师有序 Top-K，最终只保留紧凑输出。适配器可选启用，并保留固定版本 verl Worker 的共享输出头、模块 hooks 和输出布局。[3]

在 RTX 5070 Laptop GPU 上，所述 allocator fraction 下的 $N = 8192$ 实验使 PyTorch peak allocated 降低 81.05%。另一个直接 Worker 到 Student 的实验匹配了固定反向 KL 损失、所检梯度和一次受限的最终 RMSNorm 更新。GitHub CPU 回归工作流通过 171 项测试，取消选择两项完整 Trainer runtime 对照。结果属于单 GPU 实验性执行路径优化；时延数据仅作描述，不支持通用加速结论。

1 工程问题

令 N 为投影模型行数、V 为词表大小、K 为每行候选数。稠密输出头先生成 $N \times V$ logits，而响应只包含 $O(NK)$ 个值与 ID。候选集内归一化会改变评分契约：消费者需要候选 token 的全词表归一化 logprob，也需要教师自身的 Top-K。

行分块是已有方法；本项目的工作重点是将它接入真实 Worker，并保持评分和消费者接口。候选 logits 实现及逐行评分接口均有已有工作。[1, 2]

2 系统概览

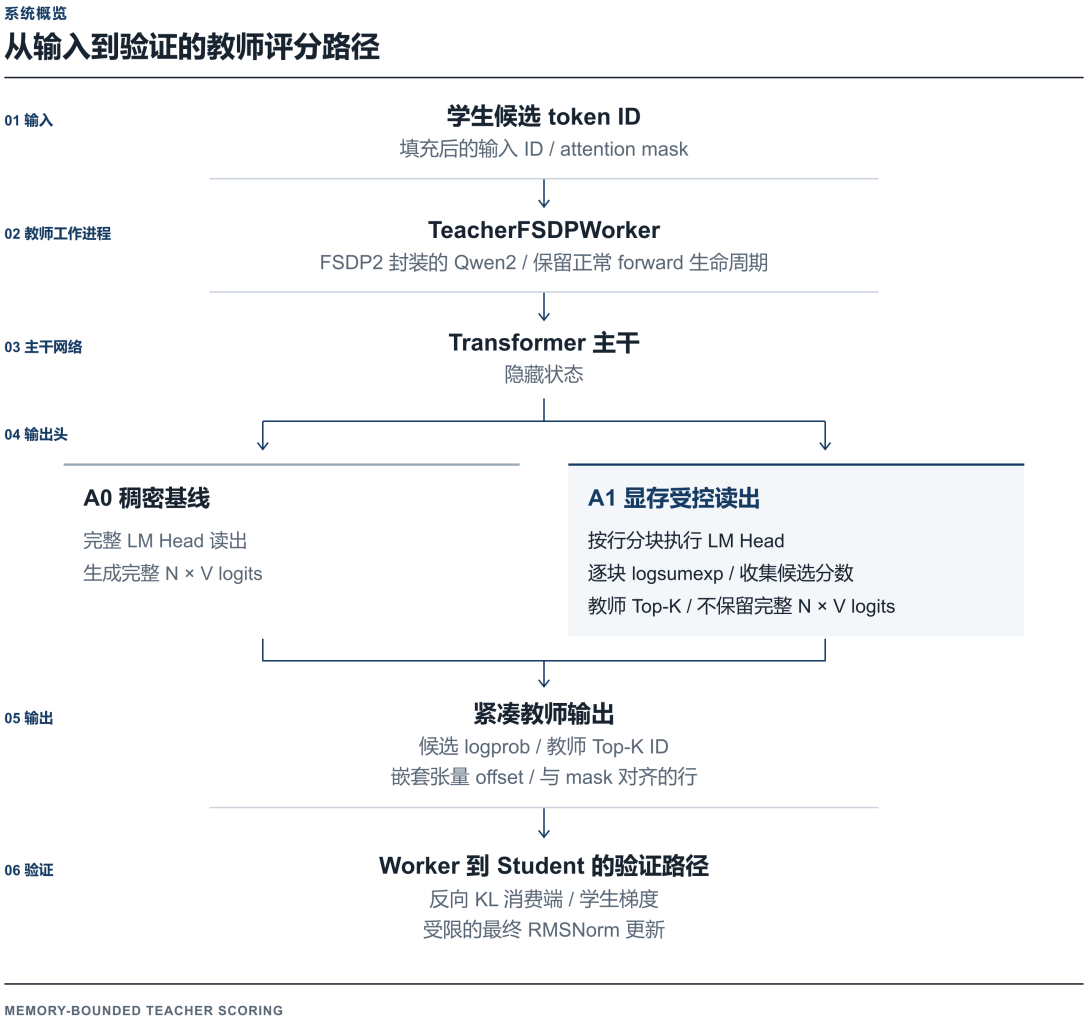


图 1：稠密和行分块读出共用教师执行路径与紧凑输出契约；最后一层表示独立的验证实验。

3 方法与实现

3.1 评分契约

对于隐藏状态行 h_t、LM Head 权重 W、偏置 b 和候选 i，返回分数为

$$z_{t,i} = h_t^{\mathsf{T}} W_i + b_i, \qquad \log p_{t,i} = z_{t,i} - \log \sum_{j \in \mathcal{V}} e^{z_{t,j}}. \tag{1}$$

归一化项覆盖完整词表。候选 ID 有序且允许重复，返回值保留其顺序；Worker 还返回完整词表上的教师 Top-K ID，并保持嵌套张量 offset 和有效行次序。

3.2 FSDP2 内的分块读出

适配器在 FSDP 封装之前安装，保留参数对象以及共享的输入 / 输出权重。请求通过正常的外层 FSDP 模块调用进入；主干网络运行一次，随后将隐藏状态按最多 B 行一块送入 LM Head 模块。每块 logits 转为 FP32，计算 log-sum-exp 和候选 gather，并保留教师 Top-K ID；各块归约后丢弃，不拼接完整 $N \times V$ 结果。

同时存活的 logits 块随 BV 而非 NV 扩展；紧凑输出仍随 NK 扩展，主干网络、模型和 FSDP 分配也仍然存在。该方法改变内存分配方式，并不消除全词表投影计算。当没有显式预算且单块覆盖全部行时，实现回退到原生稠密 forward；显式读出预算是该部分开销的估算，并非整卡硬限制。

3.3 填充与消费者对齐

候选 ID 使用准备好的 attention mask 散射到填充后的模型行，紧凑输出再恢复为有效行次序。适配器不对候选 ID 额外施加因果位移。消费者验证在相应预测位置使用 response mask，并将真实 Worker 输出送入固定版本的损失函数。

4 实验结果

4.1 实验设置

最终矩阵使用 Qwen2.5-0.5B-Instruct、BF16、单张 RTX 5070 Laptop GPU、PyTorch 2.14.1+cu130、FSDP2 CPU offload、SDPA、$K = 32$、$B = 256$ 和 allocator fraction 0.50。输入和候选 ID 均为合成数据。每个长度按 Dense–Chunked–Chunked–Dense 顺序运行四个独立进程；每进程预热一次、测量五次。N 表示投影行数。

N	模式	Alloc. MiB	Reserved MiB	p50 ms	p95 ms
1024	Dense	1517.1	2644	210.4	288.0
1024	Chunked	665.3	1124	159.4	187.0
4096	Dense	2409.4	2944	322.3	414.4
4096	Chunked	672.3	1130	318.8	327.5
8192	Dense	3596.6	3846	570.8	599.6
8192	Chunked	681.6	1126	626.3	944.6

表 1：逐次调用的 PyTorch 分配器峰值和同步预热 Worker 耗时；每组 p50/p95 汇总十次测量。

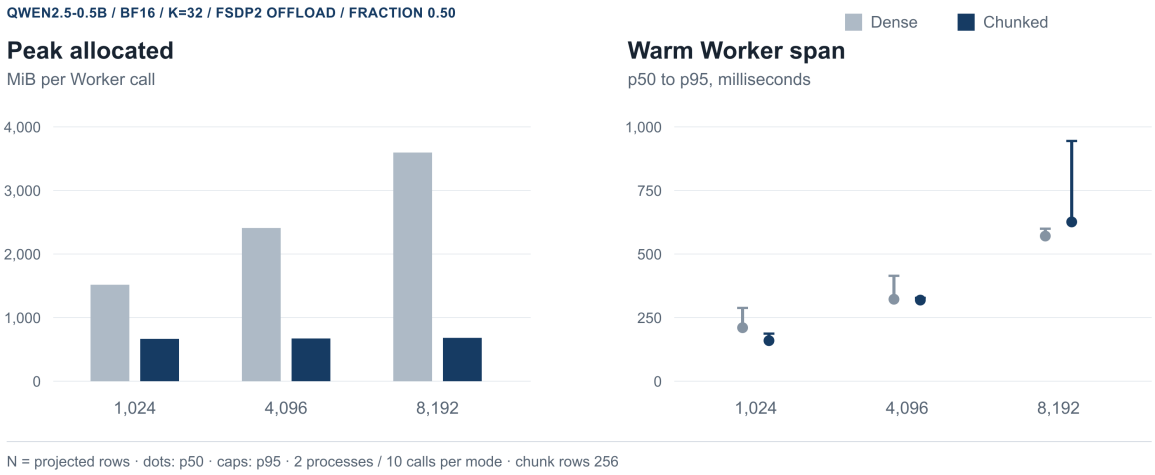


图 2：Peak allocated 和 p50 至 p95 的耗时范围；reserved 数值见表 1。

5 正确性与结果解释

$N = 8192$ 时，262,144 个候选 logprob 和 8,192 行有序教师 Top-K 均与 Dense 参考逐值一致。最终矩阵和分块大小实验保存的 96 份紧凑输出均已重新读取，并与同长度 Dense 参考比较；对照包括输出身份、形状和 offset。

$N = 8192$ 时，peak allocated 从 3,596.6 MiB 降至 681.6 MiB，降幅为 81.05%。这是逐次调用的 PyTorch 分配器测量，并非整设备 VRAM 估计。同一 fraction 下，Dense 在 8,704 行成功、9,216 行达到分配器 OOM；Chunked 在已测最大点 32,768 行运行成功，但该点没有同长度 Dense 正确性参考。

同步计时包含诊断 hooks 和嵌套输出返回 CPU 的过程。8,192 行时 Dense 的 p50/p95 为 570.8/599.6 ms，Chunked 为 626.3/944.6 ms。进程波动和主机时钟差异限制了时延解释；这些结果不支持通用加速结论。

5.1 Worker 到 Student 的验证

在独立的双序列实验中，真实 Dense 和 Chunked Worker 输出进入固定版本的反向 KL 消费端，损失、学生 logits 梯度、最终 RMSNorm 梯度以及一次受限 AdamW 更新均一致。该实验使用 $K = 8$、25 个有效响应预测行，只更新学生最终 RMSNorm 权重。早期实验中标量损失一致却出现梯度差异；将转换计算图与固定消费者对齐后，该测试输入中的差异消失。这是直接集成验证，不等于完整 RL 训练。

6 当前范围与后续工作

已测路径覆盖单 GPU FSDP2 下使用共享输出头的 Qwen2。下一阶段将扩展模型覆盖，支持 packed 变长输入，验证 FSDP1 与多 GPU / 张量并行，并接入端到端 RL Trainer。早期仅计算 selected logits 的融合方案对完整评分契约仍为 NO-GO；项目历史结果保留了相应负结果。

7 复现与证据

实验代码基线为 `ad395e94923bcf65fff4bc1eeb2e0e1505fd4f91`；Worker 集成基于 verl `87cd055e872f9fdd7b976fcd797a0934b6dba265`，模型版本为 `7ae557604adf67be50417f59c2c2f167def9a775`。Linux / Python 3.12 的独立 Worker 锁文件固定了 105 项依赖。仓库复现指南列出环境、模型哈希、命令及实验范围。

公开结果摘要包含矩阵数据，证据清单通过 SHA-256 关联归档测量。GitHub CPU 任务在实验基线上报告 171 项通过、2 项取消选择、零跳过；它检查 CPU 回归和补丁适用性，不运行 GPU 基准。

- 实验复现指南
- Worker 结果摘要与证据清单
- GitHub Actions CPU 运行记录

8 结论

将行分块边界前移至 LM Head，使该 Teacher Worker 在保留消费者所需输出的同时降低了读出期间的分配峰值。单 GPU 实测、逐值输出对照和受限 Student 更新，为下一阶段集成提供了具体依据。

参考文献

[1] Jordan Pettyjohn. IndexedLogits: indexed selected-logit CUDA implementation, 2026. URL `https://github.com/pettyjohnjn/indexed_logits/tree/6020cb446cde8cb2b74a8fdf90db905a320936c3`. Source inspected 2026-10-28; no project runtime reproduction.

[2] SGLang contributors. PR 38119: Add sparse per-position requested-token scoring, 2026. URL `https://github.com/sgl-project/sglang/pull/38119`. Source inspected 2026-10-28; no project runtime reproduction.

[3] verl contributors. Teacher scoring and student-top-K distillation, PR 6920, 2026. URL `https://github.com/verl-project/verl/pull/6920`. Experiments use source revision 87cd055e872f9fdd7b976fcd797a0934b6dba265 and a local project patch; no upstream acceptance is implied.