显存预算约束的
Teacher Scoring

保留完整契约的 FSDP 接入、分配器容量与真实 Worker-to-Student 证据

作者	Jiacheng Yu
版本	2026 年 10 月 30 日；简体中文
文稿状态	AI 辅助技术草稿；所有新增内容等待 Human 审核
证据快照	基线 `0fd56a6` 与其后的 Worker 和 mask 验证
已验证范围	单 GPU Qwen2/FSDP2；有界数值、容量与受限更新实验

审核边界。本文是新报告，不继承旧 `c1ab1f4` 中英文报告的作者审核状态。旧报告及 10 月 30 日 Markdown/PDF 增补继续作为独立快照保留。第 10 节记录后续有界 Worker 与 mask 验证及其测量范围。

显存测量随 allocator 与执行范围报告。行分块已有先例；本文不声明新的 selected-logit 内核或普遍时延收益。

摘要

Teacher 即使只返回紧凑分数，也可能先分配完整 token×vocabulary logits。本实现把行分块前移到 Qwen2 LM Head 之前，保留 Student 候选 ID 上的全词表归一化 logprob 和 Teacher 自身 Top-K。适配器在普通外层 FSDP forward 内运行，保留模块 hooks 与共享参数；无显式预算且分块覆盖全部投影行时，使用原生 dense forward 回退。受控单 GPU 实验完成 384 次直接模型调用及 64 次真实 Worker 调用，没有复现先前 CUDA abort。在 PyTorch allocator fraction 0.25 下，offload 开启的 dense 路径在 1536 行成功、2048 行 OOM，chunked 执行到 32768 行，但同长度 dense 数值校验只到 8192。fraction 0.50 下，dense 在 8704 成功、9216 失败；更高预算的 dense 参考验证了 chunked 的 9216 行输出。真实 Worker 输出还保留了固定 loss、所检梯度和一次最终 RMSNorm AdamW 更新。后续真实 Worker 在 8192 行与同预算 Dense 一致，在 9216 行与较高预算 Dense 参考一致。无人工 fraction 的 1024 行实验测量显存，并未测容量上限；完整 RL 训练和 Ray 调度仍未覆盖。

目录

1 问题动机与贡献边界 **2**

2 完整评分与消费契约 **2**

3 FSDP 执行与受限读出 **3**

3.1 模块与 hooks 生命周期 3

3.2 CPU offload 与 dense fallback 4

3.3 预算估计及约束范围 4

4 实验设计与执行身份 **4**

4.1 Worker 对齐的 buffer 构建 5

5 S1：受控稳定性 **5**

6 明确 allocator fraction 下的容量 **5**

7 M1 与 T1：显存口径和描述性时延 **6**

7.1 Allocator 峰值与整设备观察 6

7.2 Worker 对齐的完整 forward 配对时延 6

8 I1：真实 Worker 输出进入受限 Student 更新 **6**

9 负结果与证据解释 **7**

10 真实长序列 Worker、自然分配与 response mask 验证 **7**

11 最终有界 Worker 对照 **8**

12 复现入口与技术判断 **10**

1 问题动机与贡献边界

蒸馏消费者所需的信息不同：指定 logits、条件概率、全词表 logprob 和 Teacher Top-K 是不同契约。返回 NK 个数值的接口，内部仍可能执行和分配 NV 投影。其中 N 为实际经过 Head 的模型行数，V 为词表大小，K 为候选宽度；padding 行也计入 N。

逐行评分接口与索引 selected-logit 原语已经处理其中部分问题。此前源码调查记录了相关 SGLang、vLLM 接口及 IndexedLogits，这些观察仍限定在当时的固定版本。[1, 3, 5, 8] 本报告的工程对象更具体：在固定 verl 的 Qwen2/FSDP 执行中，限制 logits tile 的分配，同时保留完整 Teacher 契约。行分块是已有方法；此前仅计算 Student 候选 logits 的融合方案，对完整契约仍为 **NO-GO**。

目标为 verl PR #6920 的固定版本[7] `87cd055e872f9fdd7b976fcd797a0934b6dba265`。补丁显式启用，关闭时保留上游分支。源码观察及本地运行不代表上游已接受或合并。

2 完整评分与消费契约

对第 t 行，隐状态为 h_t，输出头权重为 W、bias 为 b，候选支持集为 C_t：

$$z_{t,i} = h_t^{\mathsf{T}} W_i + b_i, \tag{1}$$

$$\ell^{\text{full}}_{t,i} = z_{t,i} - \mathrm{LSE}_{j\in\mathcal{V}}\, z_{t,j}, \tag{2}$$

$$\ell^{C}_{t,i} = z_{t,i} - \mathrm{LSE}_{j\in C_t}\, z_{t,j} = \ell^{\text{full}}_{t,i} - \log Q_t(C_t). \tag{3}$$

返回值是 $\ell^{\text{full}}_{t,i}$，而非 $\ell^{C}_{t,i}$；另一输出是 Teacher 对整个词表的 Top-K。通常不能从选中 logits 重建全词表归一化分母，也无法据此确定 Teacher Top-K。因此，只投影 Student 候选不能替换当前两字段接口。

上述公式中的 C_t 表示数学支持集。实际接口承载 $[B, T, K]$ 形状的有序 int64 ID，允许重复 ID；gather 后的分数必须保留其顺序与重复次数。候选 ID 已经指向因果 logits 行，适配器不额外位移，也不改变温度。

修改后的 Worker 仍只返回 `teacher_on_student_logp` 与 `teacher_topk_ids`，为 detached CPU nested tensors，保持原有效行顺序及 offsets。候选使用实际 prepared attention mask 散射至 padded 行，再用同一 mask 还原。多序列 padded 输入在此布局路径内支持；多序列 packed/remove-padding 注意力，在真实 varlen 执行验证前明确拒绝。

作为目标区别的数学背景，固定支持集上的条件反向 KL 为：

$$p^C_i = \frac{e^{z^S_i/\tau_S}}{\sum_{j\in C} e^{z^S_j/\tau_S}}, \qquad q^C_i = \frac{e^{z^T_i/\tau_T}}{\sum_{j\in C} e^{z^T_j/\tau_T}}, \tag{4}$$

$$L_C = \sum_{i\in C} p^C_i \log \frac{p^C_i}{q^C_i}, \tag{5}$$

$$\frac{\partial L_C}{\partial z^S_j} = \frac{p^C_j}{\tau_S}\left(\log \frac{p^C_j}{q^C_j} - L_C\right), \quad j \in C. \tag{6}$$

它说明条件重归一化后共同全词表分母会相消，并不表示所有 OPD loss、clamp 和 mask 都等价。条件 KL 忽略支持集总质量差异及尾部分布：

$$D_{\mathrm{KL}}(P\|Q) = D_{\mathrm{Ber}}(\alpha\|\beta) + \alpha D_{\mathrm{KL}}(P^C\|Q^C) + (1-\alpha) D_{\mathrm{KL}}(P^{\bar{C}}\|Q^{\bar{C}}). \tag{7}$$

第 8 节实际调用固定 `compute_reverse_kl_topk` 源码，保留其归一化与 clamps，没有用上述简式替换真实消费者。此前调查也区分了这一目标与其他 OPD reward 或 subset-loss 构造。[2, 4, 6]

3 FSDP 执行与受限读出

3.1 模块与 hooks 生命周期

适配器在 FSDP 包装之前安装于普通、未包装的 `Qwen2ForCausalLM`，保留参数对象、模块树及输入输出共享权重。评分请求经 `self.engine.module(...)` 进入普通外层 FSDP forward。Backbone 与最终 norm 执行一次，随后将展平 hidden rows 分块送入 `self.lm_head(tile)`。每块都调用模块本身，使其 pre/post hooks 仍然运行；直接读取权重作矩阵乘法会绕开该生命周期。

每个至多 B 行的 tile 产生 logits，再转为 FP32 做全词表 log-sum-exp 和 candidate gather；logprob 转回 logits dtype，同时保存 Teacher Top-K ID。各块及时释放，不拼接完整 logits。紧凑输出仍占 $O(NK)$；backbone hidden state、模型与 FSDP 分配仍属于完整 forward。

已验证目标为 tied-embedding Qwen2、普通 dense linear head、BF16、world size one、eval/no-grad 与无 KV cache。适配器拒绝不支持的多 rank、untied head、LoRA、量化/QAT、Liger/fused alternative forward 和 sequence parallel。存在 FP32 代码路径不等于已有 FP32 GPU 证据；FSDP1、TP 及多 GPU 仍为 `NOT_RUN`。

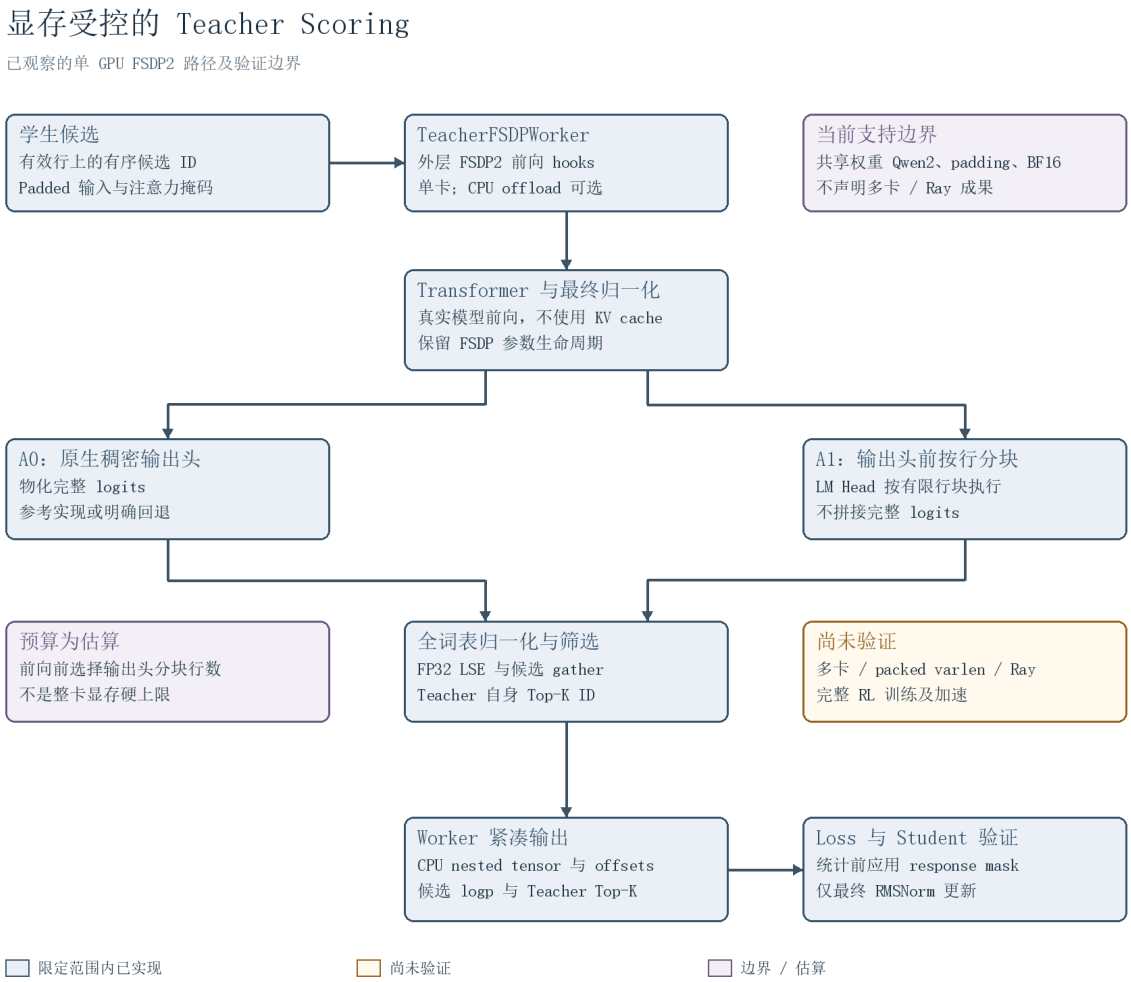


图 1: 显存受限 Teacher 执行与独立的直接 Worker-to-Student 验证路径。数值及运行范围由各实验章节限定；图示不代表尚未执行的调度或训练路径已经通过。

3.2 CPU offload 与 dense fallback

FSDP2 CPU offload 改变参数驻留，且可能主导完整 forward 时延；它不取消普通 FSDP forward 边界。受控实验直接检查 root/decoder 的 offload policy，而非仅根据命令行开关推断。

没有显式 head budget 且选中 tile 覆盖全部模型行时，走 `dense_full_row_fallback`：先完成原生 dense forward，再在 FSDP 返回后运行原 gather/reduction。若在参数仍驻留时归约完整 tile，峰值反而可能上升；早期 $N = 512$、chunk=512 的全行 tile 使绝对峰值增加约 33.7%，由此形成原生回退策略。任何显式 head budget 都禁用这一自动回退，避免把请求的估计预算默默替换成无界 dense 执行。错误及 OOM 向外传播，不重试外层 forward。

3.3 预算估计及约束范围

令 s 为 logits 每元素字节数，$\gamma = 1.25$ 为默认安全因子，H 为请求的 head 字节预算。实现中的估计为：

$$M_{\text{compact}} = NK(s+8), \tag{8}$$

$$m_{\text{row}} = \lceil \gamma \left[V(s+8) + 24K \right] \rceil, \tag{9}$$

$$\widehat{M}(B) = M_{\text{compact}} + Bm_{\text{row}}, \tag{10}$$

$$B = \min\left(N, B_{\text{requested}}, \left\lfloor \frac{H - M_{\text{compact}}}{m_{\text{row}}} \right\rfloor \right). \tag{11}$$

该式包含紧凑输出、logits tile、最多两个 FP32 词表工作张量及保守 Top-K bookkeeping。若紧凑输出加一行估计都放不下，在 forward 前拒绝。预算只约束该读出估计，不覆盖完整模型、FSDP 参数驻留、碎片、其他进程及所有 CUDA workspace。全词表投影计算量仍约为 $2NVd$；缩小 tile 是分配与更多 Head 调用之间的取舍。

早期独立的 $N = 1024, K = 32$ FSDP2 预算 probe，在 64/128/256 MiB 预算下选出 35/70/141 行；读出 allocated 增量约为 51.03/101.75/204.64 MiB，完整 forward 峰值约 552.28 MiB。它们只校准该工作负载。Head 估计与 `torch.cuda.set_per_process_memory_fraction` 约束的是不同数量。

4 实验设计与执行身份

项目	已记录的固定条件
GPU	NVIDIA RTX 5070 Laptop；8151 MiB
模型	Qwen2.5-0.5B-Instruct；BF16；共享 embedding
模型版本	`7ae557604adf67be50417f59c2c2f167def9a775`
框架	PyTorch 2.14.1+cu130；Transformers 5.19.0
分布式路径	FSDP2，world size one；offload 条件分别记录
输入	合成 tokenized sequences 与固定候选；无采样 RL 轨迹
证据来源	双语 10 月 30 日阶段增补及此前有界适配器记录

表 1: 已记录实验的执行身份。

容量点使用独立新进程、SDPA、$K = 32, B = 256$ 与单条序列；factorial fixture 则为 padded 64/37、$K = 8, B = 16$ 和 eager attention，两者不能混作同一工作负载。输出签名覆盖 shape、dtype、offsets 与 bytes；容量比较检查所有保存的紧凑候选及 Teacher Top-K 集合。若只有紧凑输出，无法证明 full-logits 边界 tie，比较器保留未决 tie/mismatch。

4.1 Worker 对齐的 buffer 构建

最初直接模型与真实 Worker 存在数值构建差异。固定 Worker 显式执行 `model.to(dtype)`，将 Qwen2 rotary frequency buffers 从 FP32 转为 BF16；原直接路径保留 FP32。对齐这一步后，31/32 个 frequency 值改变，所测 fixture 的 808 个候选值及 101 行 Teacher Top-K 恢复逐值一致。它解释这一直接/Worker 输出差异，不解释 CUDA abort。早期直接模型测量仍限定于其原始 buffer 策略。

5 S1：受控稳定性

直接模型 factorial 交叉 Dense/Chunked 与 CPU offload 开/关四种条件，每种三个新进程，每进程两次 warmup 与 30 次计数调用。实际 root/decoder FSDP policies 与请求一致，每次完成调用都核对同一紧凑参考。直接模型进程完成 384 次检查，另两个真实 Worker 进程完成 64 次并核对每次 hash

入口	条件	新进程数	完成调用
直接 Qwen/FSDP2	Dense，offload 开	3	96
直接 Qwen/FSDP2	Chunked，offload 开	3	96
直接 Qwen/FSDP2	Dense，offload 关	3	96
直接 Qwen/FSDP2	Chunked，offload 关	3	96
真实 verl Worker	Dense，offload 开	1	32
真实 verl Worker	Chunked，offload 开	1	32

表 2: 完成次数包含 warmup：每个直接模型条件为 $3(2+30)=96$。

和 offsets。首次 CUDA `unknownerror` 在此有界集合未复现；根因及同期 WSL dxg 观察仍未知。重复运行只证实该有限集合，不能据此认定长期生产稳定性。

6 明确 allocator fraction 下的容量

fraction 0.25 在此设备上对应名义 2,129,510,400 字节 PyTorch 缓存 allocator 限额，不是整设备硬隔离。边界扫描以 512-token 粒度收窄已测区间；成功/OOM 格点不证明单调性或精确最大值。fraction

Fraction	Offload	Dense 成功 / 下一 OOM N	Chunked 最大已测可执行 N	Chunked 的 dense 校验到达 N
0.25	开	1536 / 2048	32768	8192
0.25	关	512 / 1024	16384 / OOM 16896	4096
0.50	开	8704 / 9216	32768	9216

表 3: 已测格点及独立的数值等价边界。

0.25 下，offload 开启组在 $N = 1024, 2048, 4096, 8192$ 通过紧凑比较，关闭组在 $N = 2048, 4096$ 通过，logprob 最大差均为零。更长 Dense 参考使用 fraction 0.55；参考在开启组 $N = 12288$、关闭组 $N = 8192$ OOM。比较器补齐 shape/签名验证后，六组均重新比较并通过，原记录保留。

因此，开启组 8192/1536 是 5.33 倍已观察长度比；32768 仍是无完整同 N Dense 正确性参考的执行容量证据。fraction 0.50 下，Chunked 完成 8192/16384/24576/32768；8192 同预算输出一致，fraction 0.55 的 9216 行 Dense 与 fraction 0.50 Chunked 的 294,912 个候选值及全部 9216 行 Top-K 集合一致。该已验证格点比 Dense 最大已测成功 8704 多 512 tokens（5.88%）。更高预算参考提供正确性证据，不构成同预算容量比较。

7 M1 与 T1：显存口径和描述性时延

7.1 Allocator 峰值与整设备观察

指标，MiB	$N = 1024$，M1		$N = 8192$，fraction 0.50	
	Dense	Chunked	Dense	Chunked
Forward allocated 峰值	1517.09	665.31	3596.83	681.66
含 load/wrap 的进程 allocator 峰值	1517.09	958.48	3596.83	958.48
Forward reserved 峰值	1748	1572	3846	1572
整设备 used 采样最大值	3429	3258	5504	3229
设备采样次数（非 MiB）	40	30	36	33

表 4: Offload 开启的独立新进程比较。100 ms 整设备采样包含其他进程，也可能漏掉瞬时峰值。

较低的调用峰值不代表加载/包装分配消失；reserved 也依赖 allocator 历史。$N = 1024$ 两个采样最大值相差 171 MiB，并非精确净进程 VRAM 收益。fraction 0.50 的 Dense OOM 时，CUDA 仍报告约 3401 MiB 空闲，体现 allocator 限额而非整卡耗尽。本版没有无人工 fraction 的长输入 Worker 容量结果。

7.2 Worker 对齐的完整 forward 配对时延

T1 使用 $N = 1024, K = 32, B = 256$。各 offload 条件含六组 A/A 和八组交错 ABBA/BAAB，每个 A/B 标签 16 个样本。计时覆盖直接模型/FSDP 完整 forward 至紧凑 CPU 副本，排除加载及正确性校验。该口径下 allocated 分别下降 56.17%（开）和 34.52%（关）；候选最大差均为零，全部 1024

Offload	指标	A0 Dense	A1 Chunked
开	Allocated 峰值 MiB	1517.09	664.97
关	Allocated 峰值 MiB	2467.26	1615.48
开	perf-counter p50 / p95 ms	192.580 / 193.953	192.978 / 198.150
开	raw-clock p50 / p95 ms	190.491 / 191.858	190.926 / 196.081
关	perf-counter p50 / p95 ms	87.241 / 114.847	78.709 / 116.953
关	raw-clock p50 / p95 ms	87.567 / 115.198	78.986 / 117.407

表 5: 采用 Worker 对齐 buffer cast 的直接模型配对记录。

行 Teacher Top-K 集合一致。关闭 offload 的进程中，30/32 个 A/B 和 12/12 个 A/A 样本的 CUDA Event 长于包围它的 perf-counter 区间。早期运行也出现主机时钟及实验阶段漂移，原因未解。因此时延只作描述，不声明普遍加速，也不把两个独立 offload 进程当作生产性能排名。

8 I1：真实 Worker 输出进入受限 Student 更新

真实 Qwen Student 生成一次候选，随后两个固定版本的真实 `TeacherFSDPWorker` 顺序执行 Dense 回退与 Chunked。它们当前返回的内存内 CPU nested TensorDict 值散射回原 padded Student 行，直接送入 `compute_reverse_kl_topk`；没有以记录的 JSON Teacher 数值替代。

两条序列的 offsets 为 $[0, 23, 45]$，padded 模型行数为 46，$K = 8$，激活响应预测行数为 25。Student 先按 0.8 温度缩放，再 log-softmax、Top-K；Teacher 温度为 1。候选仍位于原 logits 行，只有 response mask 做 next-token 对齐。两条路径恢复相同最终 RMSNorm 权重和新的 AdamW 状态，学习率 0.01、weight decay 为零。Teacher 保持 detach；保留 support normalization、logprob 下限 -10、token loss 非负截断与最大 loss 截断 10。本 fixture 的 360 个候选值、Teacher Top-K、mass、overlap、token

观察量	Dense Worker	Chunked Worker
Masked scalar loss	0.0216006283	0.0216006283
最终 RMSNorm 梯度 L2	0.0124774044	0.0124774044
非零梯度元素	896	896
改变的 BF16 参数值	1	1
参数更新 L2	0.0099792480	0.0099792480

表 6: 真实 Worker 输出驱动的一次最终 RMSNorm AdamW 更新。

losses、6,989,056 个 Student logits 梯度元素、896 个 RMSNorm 梯度元素及更新结果逐值一致。检查了 outer/head hooks 正常完成、Teacher 无梯度，以及两个顺序 Worker Python 对象均被回收。证据覆盖本地 Worker-to-loss-to-受限更新；Ray 调度、完整 Trainer、全参数优化与 RL step 仍为 `NOT_RUN`。

9 负结果与证据解释

最初 selected-logit 提案不满足全词表归一化加 Teacher Top-K；早期全行 chunk 增加完整峰值，推动了显式原生回退策略。首次 CUDA abort 虽未在受控集合重现，根因仍未知。Buffer cast 解释一个直接/Worker 数值差异，不能用于解释该 abort。

早期项目消费者在两个梯度分支上分别把 BF16 Student logprob 转为 FP32，标量 loss 虽与上游一致，RMSNorm 与 logits 梯度的相对 L2 差异却约为 1.07% 和 1.80%。按上游图结构复用同一次 FP32 转换后，该 fixture 的差异消失。保留这一负结果，是为了说明必须核对梯度和更新，不能只接受标量 loss 一致。

早期样本在 WSL 临时存储清理后丢失，没有重建成历史事实；此处引用后续有记录运行。归档矩阵曾把全行 Head 调用误标为避免完整 logits，实际形状与标签相反，当前脚本已修正。超出 Dense 参考上限的更长 Chunked 结果，数值等价仍为 `UNKNOWN`。退出码或有限输出不替代完整数值及训练验收。

10 真实长序列 Worker、自然分配与 response mask 验证

后续实验均以新进程调用实际固定 `TeacherFSDPWorker`：共享权重 Qwen2 BF16、FSDP2 CPU offload、SDPA、$K = 32$、行块 $B = 256$。文本和候选 ID 为合成输入。每次调用记录实际输入、attention mask、position ID、offset、外层/骨干/输出头 hooks 和完整 CPU nested 输出。长度 64/37 的两个短进程覆盖真实 padding，3232 个候选 logprob 与 101 行有序 Teacher Top-K 均一致。长序列为单条因果序列，不代表长多序列 padding 已获验证。

Worker 条件	Allocated 峰值，MiB		Reserved 峰值，MiB	
	Dense	Chunked	Dense	Chunked
8192，均为 fraction 0.50	3596.638	681.630	3844	866
9216，Dense 0.55 / Chunked 0.50	3893.700	683.962	4144	884
1024，无人工 fraction，A/A 与 B/B	1517.071	665.306	2644	1124

表 7: 独立进程的完整 Worker 调用 allocator 峰值。9216 的 Dense 0.55 只作正确性参考，不构成同预算容量比较。

$N = 8192$ 时，262,144 个候选 logprob 与全部 8192 行有序 Teacher Top-K 完全一致；$N = 9216$ 的跨预算对照中，294,912 个候选及全部 9216 行有序 Top-K 完全一致。每个长序列条件只有一次冷调用，冻结 BF16 容差也通过；两个长度的 offsets 均为 $[0, N]$。这不证明 32768 行相对 Dense 正确，也不代表完整 Trainer 运行。

未调用 `set_per_process_memory_fraction` 的 $N = 1024$ 对照使用 ABBA 顺序的四个新进程，各有一次预热和三次计数调用；每个进程记录的实际 fraction 均为 1.0。A/A、B/B 和 A/B 的紧凑输出及有序 Top-K 一致。Dense 计数样本的 perf-counter 范围为 175.754–200.623 ms，Chunked 为 161.573–191.955 ms；部分样本的主机时钟存在分歧，因此只描述该小样本，不声明加速。100 ms 全设备最大采样分别为 Dense 两进程 4990/5120 MiB、Chunked 两进程 3584/3332 MiB，包含其他进程且可能漏峰。这里没有测试无人工 fraction 的容量上限。

固定 Trainer 的指标包装先按 response 行筛选，再汇总 mass、loss 范围和 overlap；overlap advantage 还要求该行 overlap 大于零。本地诊断采用同一规则并保留原始逐 token 值。CPU 回归将实际固定 Trainer 函数与手算结果比较，并覆盖 prompt/padding 极值或 NaN 和零 overlap；原 Loss 与梯度语义不变。此前 I1 记录的 CPU 重放保留 padding 行 `teacher_mass=8.0`，但在统计中排除它：25 个 response 行的 Teacher mass 均值为 0.732026、最大值为 0.999786。此重放不是新增 GPU 训练步骤。

开始时两次尝试因预登记的空闲显存门槛未满足而为 `NOT_RUN`；一次 CPU 依赖导入失败后，在 GPU 执行前修正了 runner。十个完成的 Worker 进程均记录设备采样无失败。后续 probe 修订在设备观测缺失时将实验标为失败，同时保留已完成的 Worker 输出；实际运行源码及 SHA-256 与原始测量一起保留。该错误处理修正只做 CPU 回归，不改写已记录运行。

11 最终有界 Worker 对照

最终矩阵使用固定 Worker 和 Qwen2.5 BF16 fixture，$K = 32$、SDPA、FSDP2 CPU offload、allocator fraction 0.50。$N = 1024, 4096, 8192$ 各按 Dense–Chunked–Chunked–Dense 顺序运行四个独立进程；每进程一次首次调用预热及五次计数。包含预热与分块大小实验在内的 96 份紧凑输出均重新读取，并与同长度 Dense 参考比较；本矩阵的候选 logprob 和有序 Teacher Top-K 全部逐值一致。

N	路径	Alloc. MiB	Reserv. MiB	p50 ms	p95 ms
1024	Dense	1517.1	2644	210.4	288.0
1024	Chunked	665.3	1124	159.4	187.0
4096	Dense	2409.4	2944	322.3	414.4
4096	Chunked	672.3	1130	318.8	327.5
8192	Dense	3596.6	3846	570.8	599.6
8192	Chunked	681.6	1126	626.3	944.6

表 8: 逐次 PyTorch allocator 峰值及预热后的同步 Worker 耗时；$B = 256$。每种路径及长度有两个进程、10 个计数样本；分位数使用线性插值。

$N = 8192$ 时，该 Worker 调用范围的 allocated 峰值下降 81.05%。同一 allocator fraction 下，Dense 在 8704 成功、9216 OOM，Chunked 在 16384 与 32768 成功。这些是已测点，不证明精确最大长度或整卡耗尽；32768 尚无同长度 Dense 真值。进程开始与结束的设备快照不构成完整设备峰值测量。

时延只作描述：$N = 1024$ Dense 两个进程的中位数为 229.2 和 158.0 ms，分块实验中有样本的两种主机时钟相差 8.33%。此前 $N = 8192$ 的一组冷调用为 Dense 3382.176 ms、Chunked 8756.047 ms；同步计时覆盖至 nested CPU 返回，并包含诊断 hooks 与采样；单次观察不能证明稳定变慢。首次 CUDA 错误与时钟分歧仍未归因，不声明通用加速。另外的 $N = 4096$ 单调用 profiler 中，Dense / Chunked 分别记录 97 / 112 次 `aten::mm`（self CUDA 88.8 / 103.6 ms）、1 / 16 次 `aten::topk`（18.0 / 19.7 ms）以及各 290 次锁页内存到设备拷贝（设备事件合计 74.9 / 73.3 ms）。矩阵乘法、传输与归约均构成观察到的工作；这些类别可能重叠或嵌套，且 profiler 引入开销，不能将时长相加当作关键路径或无插桩延迟。

既有真实 Worker-to-Student 实验比较了固定反向 KL loss、梯度及受限 RMSNorm 更新；新增 CPU 重放在每个长度抽取 16 行，比较固定上游 loss 和 Student logits 梯度，候选为合成 ID。这不是实际 Student 轨迹或完整 RL 训练。

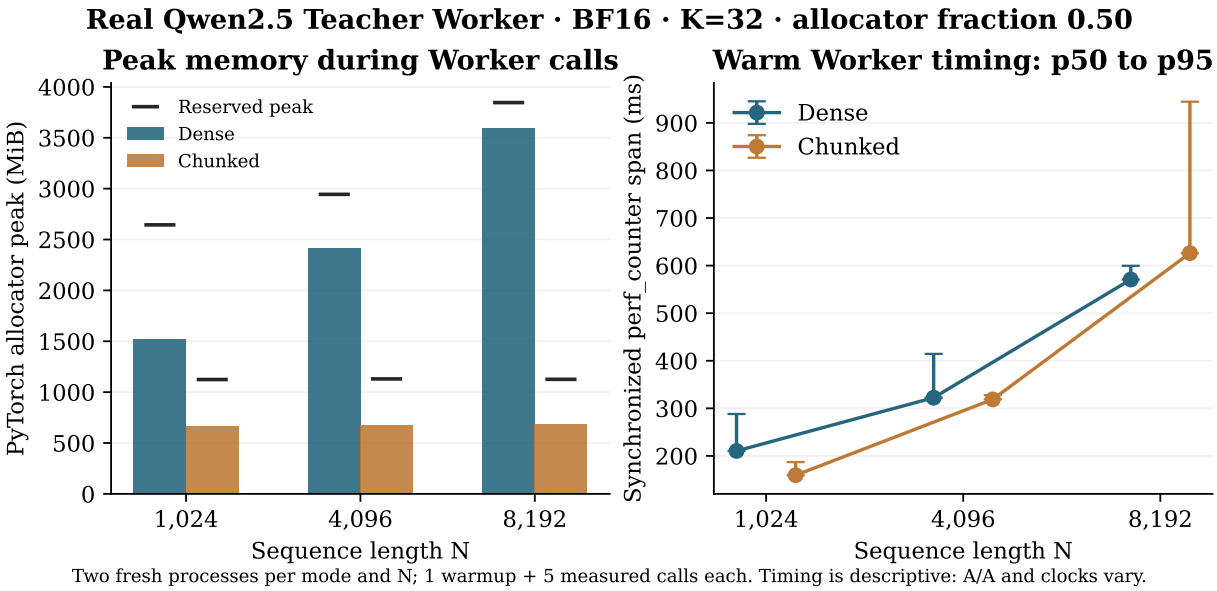


图 2: 实测 allocator 峰值和描述性 Worker 耗时。黑色标记为 PyTorch reserved 峰值，不是整卡显存。

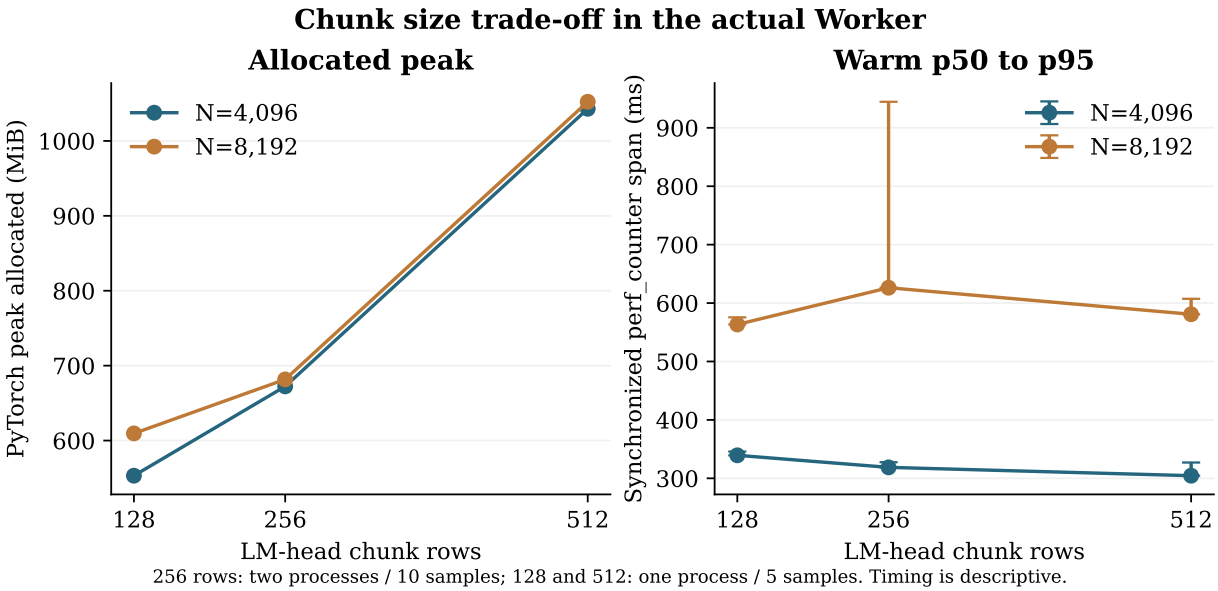


图 3: 分块大小对照。256 行使用两个进程、10 个样本；128 和 512 行各使用一个进程、五个样本。

12 复现入口与技术判断

独立干净 scoring 检出以 `0273017` 为基准并加入包导入修复；新建 Python 3.12 环境从 105 项哈希锁安装依赖。固定模型单独下载并核对哈希后，真实 Dense 与 Chunked N=1024 Worker 的 32,768 个候选值和 1024 行有序 Top-K 完全一致。该干净检出在 CUDA 可用时通过 195 项测试；包含采样器回归的最终工作树通过 199 项。此前依赖和导入失败保留在私有实验证据中。公开的 `results/worker-evidence-manifest.json` 用 SHA-256 绑定原始工件；原始证据包保存在私有项目工作区。

源码基线为 `0fd56a618800b5298d8c45529dda675f910c6e47`；后续 Worker probe 与 mask 回归位于包含本报告的版本。原始记录绑定实际测量时所用 probe 的源码字节。固定 loss 为 真实 verl FSDP distillation loss，Git blob 为 `97d3ebf485a5ce9e1b1a435cce427d6d89284dc6`。原始测量附模型与 tokenizer 哈希、命令参数和源码身份。

主要入口包括 `scripts/long_worker_probe.py`、`scripts/factorial_teacher_probe.py`、`scripts/compare_capacity_outputs.py`、`scripts/full_teacher_benchmark.py` 和 `scripts/worker_to_student_step.py`。证据标识包括 `S1_SUMMARY.json`、`capacity_runner.jsonl`、`compare_validated_summary.json`、`compare_on_n9216.json`、`T1_worker_aligned_on/off.json` 与 `worker_to_student_01.json`。前述表格据双语 Markdown 阶段增补转录；上节的新结果来自记录的 Worker 调用与 CPU mask 回归。

可支持的判断是：在所述单 GPU 环境中，保留完整评分契约的受限读出具有实测 allocator 容量收益，并完成了真实受限消费者更新。FP32 GPU、FSDP1、TP/多 GPU、packed varlen、LoRA/量化/QAT、Ray 传输、代表性 RL 轨迹、全模型训练和生产稳定性仍未验证；普遍时延收益、精确整设备 VRAM 节省及训练质量提升未获证实。全部新增正文继续保持 AI 辅助、等待 Human 审核。

参考文献

[1] Jordan Pettyjohn. IndexedLogits: indexed selected-logit CUDA implementation, 2026. URL https://github.com/pettyjohnjn/indexed_logits/tree/6020cb446cde8cb2b74a8fdf90db905a320936c3. Source inspected 2026-10-28; no project runtime reproduction.

[2] Jordan Pettyjohn. Subset-KL: subset objective implementation, 2026. URL https://github.com/pettyjohnjn/subset-kl/tree/69a813ce2233bdf243a39e7d76926ece8af76ed4. Source inspected 2026-10-28; no project runtime reproduction.

[3] Jordan Pettyjohn, Mansi Sakarvadia, Nathaniel Hudson, Daniel McKenzie, Kyle Chard, and Ian Foster. Interpreting Language Model Hidden States at Scale, 2026. URL https://arxiv.org/abs/2608.10260v1. Audited version 2608.10260v1; relevant methods and experimental sections read, not reproduced. Retrieved 2026-10-28.

[4] Rethinking OPD contributors. Current author implementation: rewards and actor update contract, 2026. URL https://github.com/Thinking-Space/Rethinking-OPD/tree/ac26e38d6f1572eb027597b48a9f4e01f6915ef8. Source inspected 2026-10-28; no project runtime reproduction.

[5] SGLang contributors. PR 38119: Add sparse per-position requested-token scoring, 2026. URL https://github.com/sgl-project/sglang/pull/38119. Source inspected 2026-10-28; no project runtime reproduction.

[6] verl contributors. Issue 6676: Student-top-k renormalized reverse-KL OPD, 2026. URL https://github.com/verl-project/verl/issues/6676. Source inspected 2026-10-28; no project runtime reproduction.

[7] verl contributors. Teacher scoring and student-top-K distillation, PR 6920, 2026. URL https://github.com/verl-project/verl/pull/6920. Experiments use source revision 87cd055e872f9fdd7b976fcd797a0934b6dba265 and a local project patch; no upstream acceptance is implied.

[8] vLLM contributors. PR 56984: Per-row candidate IDs for prefill token scoring, 2026. URL https://github.com/vllm-project/vllm/pull/56984. Source inspected 2026-10-28; no project runtime reproduction.