AI INFRASTRUCTURE / ENGINEERING SUPPLEMENT

显存预算约束的 Teacher Scoring

受控稳定性、分配器预算下的容量与真实 Worker-to-Student 验证

作者	Jiacheng Yu

版本	2026 年 10 月 30 日	简体中文
范围	在 RTX 5070 Laptop 单 GPU 上，固定 Qwen2.5-0.5B 与 verl 源码，分别检验稳定性、容量和受限 Student 更新。

1. 问题与执行契约

Teacher 即使只返回紧凑分数，也可能先分配完整的 token×vocabulary logits。本项目把行分块前移到稠密 LM Head 之前，同时保留两项输出：Student 候选 ID 上的全词表归一化 logprob，以及 Teacher 自身的 Top-K ID。此前仅凭融合 selected logits 替换完整契约的方案仍为 NO-GO。分块本身已有先例；本项目的工程价值在于固定 Teacher 执行链与消费接口的接入。

本阶段分别检验首次 CUDA 异常能否在受控条件下复现、明确 allocator 预算时可执行的 Token 长度，以及真实 Worker 输出能否保留 Student 更新。直接模型/FSDP 实验与实际 verl Worker 执行在报告中分别标明。

表 1. 固定执行条件。

项目	固定条件
硬件	NVIDIA RTX 5070 Laptop GPU，8151 MiB
模型	Qwen2.5-0.5B-Instruct，BF16，共享 embedding
模型版本	7ae557604adf67be50417f59c2c2f167def9a775
框架	PyTorch 2.14.1+cu130；Transformers 5.19.0
verl 源码	PR #6920，87cd055e872f9fdd7b976fcd797a0934b6dba265
支持范围	World size 1、无 KV cache、padded 文本输入

2. 受控稳定性（S1）

直接模型实验比较 Dense/Chunked 与 FSDP2 CPU offload 开/关四种条件，每种条件使用三个新进程。各进程在同一 padded 64/37-token 输入、K=8、B=16 下执行两次预热与 30 次计数调用。每次完成后记录输出哈希和 offsets，并检查 root、decoder 的实际 offload policy。

表 2. 按入口与条件记录的稳定性完成调用。

执行入口	条件	新进程数	完成调用数
直接 Qwen + FSDP2	Dense，offload 开	3	96
直接 Qwen + FSDP2	Chunked，offload 开	3	96
直接 Qwen + FSDP2	Dense，offload 关	3	96
直接 Qwen + FSDP2	Chunked，offload 关	3	96
实际 verl Worker	Dense，offload 开	1	32
实际 verl Worker	Chunked，offload 开	1	32

12 个直接模型进程完成 384 次调用并通过所检紧凑输出契约；另两个实际 Worker 进程共完成 64 次调用。原 CUDA unknown error 在这一有界集合中未复现。其根因仍未知：结果既未确认 offload/分块是原因，也未证明长期生产稳定性。

3. 明确 allocator 预算下的容量

容量扫描的每个点均使用新进程、BF16、K=32、B=256、SDPA 与一条因果序列。通过 torch.cuda.set_per_process_memory_fraction(0.25) 设置本进程 PyTorch 缓存 allocator 限额，对该设备相当于名义 2,129,510,400 字节。它约束 allocator，不是整卡 GPU 显存硬隔离。

扫描逐步增加 N，并以 512-token 粒度收窄失败区间。成功表示所要求的紧凑输出路径完成且保存了有限值；没有同 N dense 真值的长度仍不能据此判定完整数值正确。

表 3. Allocator fraction 0.25 下的容量扫描。

CPU offload	路径	最大已测成功 N	最小已测 OOM N	同 N dense 校验到达
开	Dense	1536	2048	参考路径
开	Chunked	32768	未观察到	8192
关	Dense	512	1024	参考路径
关	Chunked	16384	16896	4096

Offload 开启的 Chunked 路径到达本次测试的模型 context 上限 32768，尚无已测失败上界。关闭 offload 时，16384 成功、16896 OOM 构成已测区间；不能据此保证任意中间形状或未测输入。

3.1 容量结果的正确性边界

N=1024 的 offload 开启比较来自同为 0.25 的两条路径。其余更长 dense 参考使用独立的 0.55 allocator 比例，在相同 N、模型和执行策略下，与 0.25 Chunked 运行保存的全部紧凑行、候选及 Teacher Top-K 集合比较。

表 4. 修正版同 N 紧凑输出对照。

CPU offload	修正版比较器通过的同 N 对照	失败的 dense 参考
开	1024、2048、4096、8192；logprob 最大差 0	12288：OOM
关	2048、4096；logprob 最大差 0	8192：OOM

因此，有数值正确性支撑的已测长度，从 0.25 Dense 的 1536 扩展到 offload 开启时的 8192，从 512 扩展到关闭时的 4096。更长 Chunked 成功仍只作为可运行容量证据。高预算参考不能变成同预算的内存性能比较。比较器补齐 shape/签名校验后，六组结果重新运行并通过，旧比较记录保留。

3.2 第二 allocator 预算：0.50

预登记的后续检查在 CPU offload 开启时使用 0.50 PyTorch allocator 比例。Dense 在 N=8704 成功，在下一 512-token 格点 N=9216 OOM。Chunked 在已测 8192/16384/24576/32768 点均完成；32768 的成功仍只作为可运行证据，不代表该长度已经数值等价验证。

表 5. Allocator fraction 0.50 下的容量观察。

条件	最大已测成功 N	下一已测 OOM N	Chunked 的 dense 校验 N
Dense，fraction 0.50	8704	9216	参考路径
Chunked，fraction 0.50	32768	未观察到	9216

N=8192 时两条路径同用 0.50，全部保存的候选 logprob 与 Teacher Top-K 行一致。为检验超过 Dense 0.50 边界的点，另用 fraction 0.55 的 Dense 在 N=9216 作参考，与 fraction 0.50 的 Chunked 输出比较：294,912 个候选数值和全部 9216 行 Teacher Top-K 集合逐值一致。因此在本测试格点上，有正确性支撑的长度比最大已测 Dense 成功 8704 多 512 tokens，约 5.88%；它不是对全部中间形状或精确最大值的保证。

N=8192 的同长度显存观察

表 6. N=8192 的独立进程显存观察。

测量	Dense，fraction 0.50	Chunked，fraction 0.50
Forward-call allocated 峰值，MiB	3596.83	681.66
含加载/包装的进程 allocator 观察峰值，MiB	3596.83	958.48
Forward-call reserved 峰值，MiB	3846	1572
整设备 used 采样最大值，MiB	5504	3229
设备采样数	36	33

两组使用相同 N 的独立新进程，紧凑输出已经比较。进程 allocator 观察峰值包含加载、包装与调用；较低的调用峰值并不意味着初始化分配消失。整设备最大采样值仍受 100 ms 采样范围限制，可能包含无关占用并漏峰，不是精确进程峰值，也不是净 VRAM 收益归因。

两个 allocator 比例给出了不同的已测容量区间。0.50 对照加强了“结果依赖所声明内存限额”的观察，并没有验证最长 Chunked 成功点；两组预算下的 dense 参考边界均继续明确保留。

4. 显存与时延对应不同测量口径

独立的配对 T1 实验采用 Worker 对齐的 buffer 构建、N=1024、K=32、B=256，测量完整直接 Qwen/FSDP2 前向至紧凑 CPU 输出；加载和校验在计时区间之外。各 offload 设置包含六组 A/A 与八组交错 ABBA/BAAB，每个 A/B 标签 16 个样本。

表 7. N=1024 配对完整前向的 allocated 峰值。

CPU offload	A0 allocated 峰值 MiB	A1 allocated 峰值 MiB	观察到的下降
开	1517.09	664.97	56.17%
关	2467.26	1615.48	34.52%

表 8. T1 配对主机时钟样本的描述性统计。

CPU offload / 时钟	A0 p50 / p95 ms	A1 p50 / p95 ms
开 / perf_counter	192.580 / 193.953	192.978 / 198.150
开 / MONOTONIC_RAW	190.491 / 191.858	190.926 / 196.081
关 / perf_counter	87.241 / 114.847	78.709 / 116.953
关 / MONOTONIC_RAW	87.567 / 115.198	78.986 / 117.407

两组 T1 的候选 logprob 最大差均为 0，Teacher Top-K 在全部 1024 行一致。关闭 offload 的组中，30/32 个 A/B 样本和 12/12 个 A/A 样本的 CUDA Event 却长于包围它的 perf-counter 区间。主机时钟分歧尚未解决。因此这些是描述性时延，不支持通用加速，也不宜把不同 offload 进程直接解释为生产性能优劣。

N=1024 的独立进程观察

M1 的 offload 开启 Dense/Chunked 对照说明 allocator 与设备采样必须分开报告。

表 9. N=1024 的独立进程显存观察。

测量	Dense	Chunked
Forward-call allocated 峰值，MiB	1517.09	665.31
含加载/包装的进程 allocator 观察峰值，MiB	1517.09	958.48
Forward-call reserved 峰值，MiB	1748	1572
整设备 used 采样最大值，MiB	3429	3258
设备采样数	40	30

设备采样每 100 ms 查询一次 nvidia-smi，包含桌面及其他进程，且可能漏掉瞬时峰值。两个采样最大值相差 171 MiB，不能据此宣称净进程 VRAM 收益；同样不能把 allocated 下降扩大为整卡显存或 RL 训练收益。

5. 真实 Worker 输出进入受限 Student 更新

I1 补齐本地内存内的消费链。真实 Student 先生成一次候选，然后两个实际固定 verl TeacherFSDPWorker 分别执行 Dense 回退和 Chunked 评分；它们当前返回的 CPU nested TensorDict 直接映射回原 Student padded 行，并送入固定 compute_reverse_kl_topk 原函数。此路径没有用记录的 JSON 教师分数代替 Worker 输出。

输入为两条 prompt/response 序列，offsets 为 [0,23,45]，padded 模型行数 46，K=8，激活的响应预测行 25。Student 先按温度 0.8 缩放，再 log-softmax、Top-K；Teacher 温度为 1。候选不再额外位移，只有 response mask 按 next-token 预测行对齐。

两条 Student 路径均恢复相同最终 RMSNorm 初值和新的 AdamW 状态，学习率 0.01，weight decay 0。损失保留候选支持集归一化、logprob 下限 -10、token loss 非负截断及最大损失截断 10；Teacher 张量保持 detach。

表 10. 真实 Worker-to-Student 受限更新。

观察量	Dense Worker 输出	Chunked Worker 输出
Mask 后标量 loss	0.0216006283	0.0216006283
最终 RMSNorm 梯度 L2	0.0124774044	0.0124774044
非零 RMSNorm 梯度元素	896	896
一步后改变的 BF16 参数值	1	1
参数更新 L2	0.0099792480	0.0099792480

本 fixture 中，候选 logprob、Teacher Top-K、mass、overlap、token loss、全部 6,989,056 个 logits 梯度元素、896 个 RMSNorm 梯度元素和更新结果逐值一致。两个 Worker Python 对象均在顺序生命周期边界被回收；实际 outer/head 前后 hook 正常完成，Teacher 未产生梯度。

该证据覆盖本地直接 Worker-to-Loss-to-受限更新。它没有运行 Ray 调度、完整 Trainer、全参数优化或 RL step；训练证据明确限定为一个参数组的一步更新。

6. 解释、负结果与后续工作

本阶段形成三项具体结果：受控 2×2 集合没有复现原生 CUDA abort；head 前行分块在明确 allocator 限额下允许更长的已测输入，但 fraction 0.25 的 dense 参考正确性只证实到 offload 开启 N=8192、关闭 N=4096，fraction 0.50 的开启组证实到 N=9216；真实 Worker 当前输出保留了固定上游损失与受限 Student 更新。

在比较直接模型与 Worker 之前发现了构建差异：固定 Worker 在加载后显式执行 model.to(bfloat16)，使非持久 rotary-frequency buffers 舍入为 BF16，原直接路径则保留 FP32。应用 Worker 的构建策略后，所测 fixture 的输出差异消失。这一数值解释与 CUDA unknown error 的归因是两个问题。

首次 CUDA unknown error、同期 WSL dxg 观察和双时钟分歧继续保持开放。超过 dense 参考上限的更长 Chunked 输入仍为数值等价 UNKNOWN。FP32 GPU、FSDP1、多 GPU/TP、packed varlen 注意力、LoRA/量化/QAT、Ray 传输、代表性 RL 轨迹和完整模型训练，均不在本阶段已验证支持范围内。

此前 56.17% 的 allocated 测量和当前容量区间均有明确条件；它们没有证实整卡 VRAM 下降、新融合 Kernel、普遍时延改善或生产可用。原 fused selected-logit 路线对完整 Teacher 契约仍为 NO-GO。

复现与证据标识

代码基线为现有项目仓库的 06f0abc0945a98fe94d732f4ee0ab875948cdb43。下列新增脚本位于包含本增补的后续版本，父基线本身不包含它们；复现时须使用相应后续提交或源码包，源码哈希随原始测量记录。主要入口为：

- scripts/factorial_teacher_probe.py：每个新进程只执行一个 Dense/Chunked 与 offload 条件。
- scripts/compare_capacity_outputs.py：与同 N dense 输出比较全部紧凑候选行和 Teacher Top-K 集合。
- scripts/worker_to_student_step.py：真实本地 Worker 输出进入固定上游 loss 和一次受限更新。
- scripts/build_stage_report_20261030.py：从两份 Markdown 正文重新生成本报告 PDF。

证据标识包括 S1_SUMMARY.json、capacity_runner.jsonl、compare_validated_summary.json、compare_on_n9216.json、T1_worker_aligned_on/off.json 与 worker_to_student_01.json，分别保留成功、OOM、正确性边界及未运行项目。

参考来源

- verl PR #6920 固定源码。
- 固定 FSDP reverse-KL loss，Git blob 97d3ebf485a5ce9e1b1a435cce427d6d89284dc6。
- Qwen2.5-0.5B-Instruct 模型快照。