候选集条件
教师评分

系统背景、概率契约、已有工作与评估设计

作者	Jiacheng Yu
版本	2026 年 10 月 29 日；简体中文
文稿状态	AI 辅助初稿；作者审核待完成
研究状态	技术假设仍待核实；项目优化尚未实现
测量状态	CPU 数值、梯度、GPU、HTTP 及训练实验尚未执行

范围。 本报告研究教师推理中逐位置候选评分的一种可能契约，记录上游行为及数学边界；它不构成已测得的加速或新内核声明。

摘要

后训练消费者可能需要在不同因果位置请求不同候选 token 的教师分数。紧凑的候选条件路径是否有价值，取决于消费者的具体损失、已有 API 语义、因果对齐及端到端开销。SGLang 已有逐项评分和位置选择；一个针对特定分支的开放拉取请求实现了逐位置 ID，但仍使用全词表归一化。vLLM 已合并逐行接口，IndexedLogits 已提供候选 logits 计算原语。条件反向 KL 并非全词表 KL；所核查的 Rethinking OPD 实现也不能直接以仅条件化的分数替换。这些发现缩小了潜在贡献范围，但尚未证明贡献成立。本项目没有数值、GPU、服务或训练结果。

目录

1 问题与研究边界 2

2 已有工作与源码快照 2

3 数学契约 2

4 消费者与因果对齐 3

5 架构与可能变更 3

6 解析成本模型 3

7 评估设计 5

8 限制与判断标准 5

9 文档复现 5

1 问题与研究边界

在线策略蒸馏（On-Policy Distillation，OPD）可能需要教师评估学生轨迹。采样 token 目标、教师 Top-k 损失和学生 Top-k 条件目标要求不同输出。verl 中关于学生 Top-k 重归一化反向 KL 的需求是具体信号，但不代表所有训练系统都需要这一契约。[13–15]

令 R 为选中的因果行数，C_t 为第 t 行的候选 ID。如果某接口只能接受候选并集 $U = \bigcup_t C_t$，则可能返回 $R|U|$ 个分数，而实际需要 $\sum_t |C_t|$ 个。每行候选数相同为 K 且重叠较少时，$|U| \le \min(V, RK)$。这只是该接口契约下的输出数量模型，并非实测字节缩减，也不能推广到 SGLang 的全部路径。

位置选择、逐行候选选择和归一化是三个独立问题。返回分数变少不能证明投影计算减少；仅凭选中 logits 无法重建全词表归一化分母。完整强化学习训练收益必须通过真实、匹配的训练测量证明。

2 已有工作与源码快照

在 SGLang 版本 `4517a5ff1bbd1f944d6bde1819300ed14af7b698` 中，通用预填充 logprob 路径将请求级候选列表用于相关行；独立的 `/score` 路径支持逐项标签 ID，且可按这些标签重归一化。指定位置评分也已存在，但仍调用稠密输出头。这些机制不同，因此不能笼统宣称 SGLang 缺少候选或位置选择能力。[9–12]

截至 2026 年 10 月 29 日观察，SGLang PR #38119 对 `sglang-miles` 分支开放，并未合并到所核查的 main 版本，且保留全词表归一化。vLLM PR #56984 于 2026 年 10 月 3 日合并，已实现逐行候选接口。二者均属于已有先例。[8, 16]

OmniLens 及其 IndexedLogits 实现已经逐行计算指定 logits，并避免完整的 gathered-weight 中间张量。本项目不将该原语称为原创。相关 Subset-KL 实现的支持集与 KL 方向不同；使用相同原语不代表损失目标相同。[4–6]

Rethinking OPD 研究学生 Top-k 行为；Sparse Logit Sampling 研究另一类蒸馏问题；Tail-Aware Top-k OPD 考虑被丢弃的概率质量。其结果均为第三方观察，不能作为本项目基准结果。[1–3]

3 数学契约

对第 t 行，令 $h_t \in \mathbb{R}^d$、$W \in \mathbb{R}^{V \times d}$、$b \in \mathbb{R}^V$，非空且元素唯一的候选集合为 $C_t \subseteq \mathcal{V}$。实际模型还可能包含缩放、softcap 或适配，实施时必须保留。分数定义如下：

$$z_{t,i} = h_t^{\mathrm{T}} W_i + b_i, \tag{1}$$

$$\ell_{t,i}^{\mathrm{full}} = z_{t,i} - \mathrm{LSE}_{j \in \mathcal{V}}\, z_{t,j}, \tag{2}$$

$$\ell_{t,i}^{C} = z_{t,i} - \mathrm{LSE}_{j \in C_t}\, z_{t,j} = \ell_{t,i}^{\mathrm{full}} - \log Q_t(C_t). \tag{3}$$

其中 $Q_t(C_t)$ 是教师分布在候选集上的概率质量。对精确的全词表 logprob 再在 C_t 上归一化时，共同分母会相消；反过来，改变未选中的 logits 可以改变全词表概率，却不改变选中 logits。

固定支持集 C，令温度 τ_S, τ_T 为正且教师停止梯度。学生分布 p^C 和教师分布 q^C 定义为：

$$p_i^C = \frac{e^{z_i^S/\tau_S}}{\sum_{j\in C} e^{z_j^S/\tau_S}}, \qquad q_i^C = \frac{e^{z_i^T/\tau_T}}{\sum_{j\in C} e^{z_j^T/\tau_T}}, \tag{4}$$

$$L_C = \sum_{i\in C} p_i^C \log \frac{p_i^C}{q_i^C}, \tag{5}$$

$$\frac{\partial L_C}{\partial z_j^S} = \frac{p_j^C}{\tau_S}\left(\log \frac{p_j^C}{q_j^C} - L_C\right), \quad j \in C. \tag{6}$$

该导数由 softmax 雅可比矩阵 $\partial p_i/\partial a_j = p_i(\mathbf{1}_{i=j} - p_j)$ 得到。支持集固定时，未选中的局部 logits 梯度为零。候选选择是离散操作；并列和支持集变化不在该局部导数范围内。输入输出权重绑定及非线性输出头会引入额外梯度路径。

令 $\alpha = P(C)$、$\beta = Q(C)$，二者严格位于零和一之间。精确分解为：

$$D_{\mathrm{KL}}(P\|Q) = D_{\mathrm{Ber}}(\alpha\|\beta) + \alpha D_{\mathrm{KL}}(P^C\|Q^C) + (1-\alpha) D_{\mathrm{KL}}(P^{\bar{C}}\|Q^{\bar{C}}). \tag{7}$$

条件 KL 忽略支持集总概率差异及尾部分布结构。一个具体反例是：

$$P = (0.49, 0.49, 0.02), \quad Q = (0.005, 0.005, 0.99), \quad C = \{0, 1\}. \tag{8}$$

两侧条件分布都是 $(1/2, 1/2)$，条件 KL 为零，但全词表 KL 为正。$K = 1$ 时条件损失与局部梯度恒为零；$K = V$ 时条件目标与全词表目标一致。这些是解析结论，而不是数值测试结果。

4 消费者与因果对齐

在 Rethinking OPD 作者代码版本 `ac26e38d6f1572eb027597b48a9f4e01f6915ef8` 中，所核查路径使用全词表归一化的学生及教师 logprob 构造 log-ratio 奖励，对支持集权重归一化，再通过 PPO surrogate 使用停止梯度的优势。仅条件化的教师输出会改变该奖励，不能保持损失等价。此观察针对当前核查代码，不证明论文历史图表的代码来源。[3, 7]

实际集成必须说明哪个策略产生 C_t、候选何时可用、分词器和模型版本以及 next-token 位移。记录 rollout 支持集、学生预计算和调整执行顺序分别有不同的陈旧性与成本。当前尚未确认真正消费所提直接条件反向 KL 的训练端。

5 架构与可能变更

图 1 区分上游已有操作、拟议组件和已有先例。候选分支将在稠密 LM Head 投影前介入，并提供显式条件输出契约。稠密参考和候选实现必须在位置、有序 ID、掩码、归一化、模型变换和错误行为上保持一致；全词表归一化路径仍是不同语义。

6 解析成本模型

当每行候选数均为 K，忽略 bias 和其他变换时，近似运算量为 $2RVd$ 与 $2RKd$。实际时间取决于有效算力、内存流量、启动、校验和打包。如果可优化部分占基准请求时间的比例为 f，其加速倍数为 s，则末式为 Amdahl 定律：

$$F_{\mathrm{dense}} \approx 2RVd, \qquad F_{\mathrm{selected}} \approx 2RKd, \tag{9}$$

$$T \gtrsim \max(F/P_{\mathrm{eff}}, B/\mathrm{BW}_{\mathrm{eff}}) + T_{\mathrm{launch}} + T_{\mathrm{validate}} + T_{\mathrm{pack}}, \tag{10}$$

$$S_{\mathrm{request}} = \frac{1}{(1-f) + f/s}. \tag{11}$$

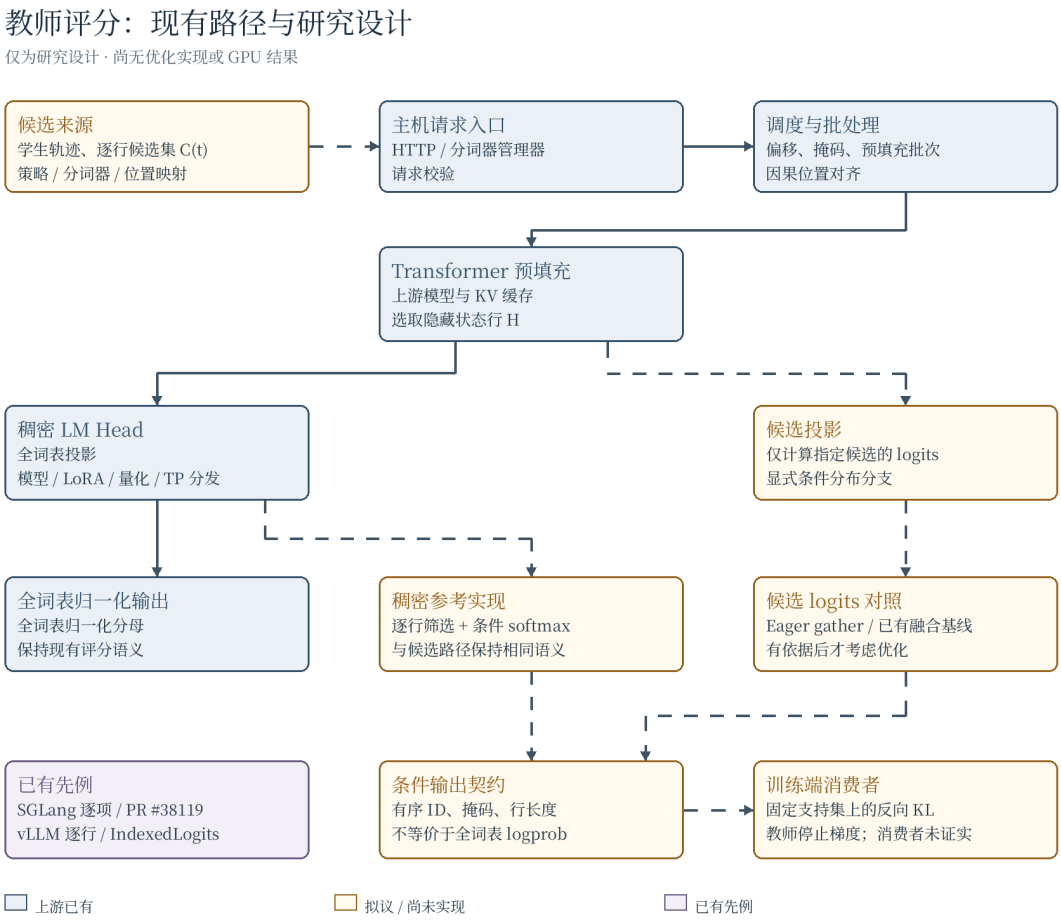


图 1: 使用同一拓扑生成的中文标签图。虚线拟议路径尚未实现。

FLOP 比例不能直接预测延迟：稠密矩阵乘法可高效复用权重，而不规则 gather 可能浪费带宽并增加启动次数。完整模型权重通常仍需驻留。候选重叠、批量和形状都可能改变最佳实现。

仅为解析示例。 当 $R = 128$、$d = 1024$、$V = 131072$、$K = 32$，每元素两字节时，输出头权重占 256 MiB、稠密 logits 占 32 MiB、eager gathered-weight 张量占 8 MiB、候选 logits 占 8 KiB。这些只是张量大小恒等式，不是实测 GPU 峰值显存。假设 $f = 0.1$，即使完全消除该部分，整体请求加速上限也只有 $1/0.9$；实际 f 未知。

7 评估设计

以下实验均为拟议方案，**尚未执行**。原生全归一化路径只作为背景；针对相同条件契约比较稠密投影加 gather、分块稠密、eager 索引 gather，以及兼容时的已有 IndexedLogits 实现。未来候选方案应在相关工作负载上胜过正确的强基线，而不是只胜过最慢基线。

先用 CPU FP64 参考检查 logits、归一化、损失和学生梯度。覆盖 $K = 1$、$K = V$、候选排列、非法或重复 ID、变长行、掩码、未选 logits 变化和因果偏移一位的情况。在比较实现前确定容差与量化输入；教师值必须停止梯度。不支持的 LoRA、量化或张量并行模式须明确拒绝，或采用保持语义且纳入测量的回退路径。

性能测量需冻结硬件、驱动、框架、模型与分词器版本、轨迹、数据类型、掩码、批处理和计时边界。覆盖候选重叠高低、代表性行数与 prompt 长度、可行并发以及 OOM/回退情况。先建立稳定 A/A 对照，再随机化成对 A/B；保留失败和负结果。分别测量内核及完整 HTTP 请求延迟，包括 p50/p95、吞吐、显存、负载字节数和错误率。分析器应与主要计时分开。仅教师轨迹回放不等于完整训练运行。

8 限制与判断标准

实际消费者以及相对于上述 API 和内核是否仍有缺口均未解决。本项目尚未执行 CPU 数值、梯度、GPU、HTTP 或真实训练实验。现无项目加速、显存节省、训练质量收益或原创候选 logits 原语的证据。只有具体消费者、固定语义和相对已有路径的可复现比较共同成立时，剩余缺口才可信；条件不满足时应记录无结论或负结果。

本报告为 AI 辅助初稿，作者审核和修订待完成。源码调查限于所引用快照，并非穷尽式新颖性检索。上游源码和论文归原作者；此处未打包第三方实现。核查范围内 IndexedLogits 仓库未声明许可证，后续复用须另行分析授权。

9 文档复现

在仓库根目录安装 XeLaTeX、BibTeX、Poppler、Python 和 Pillow，并按 README 使用随附字体子集后，运行 `bashscripts/build_assets.sh` 和 `python3scripts/verify_assets.py`。这些命令只重建文档资产，不运行 SGLang，也不测试研究假设。

参考文献

[1] Anshumann, Mohd Abbas Zaidi, Akhil Kedia, Jinwoo Ahn, Taehwak Kwon, Kangwook Lee, Haejun Lee, and Joohyung Lee. Sparse Logit Sampling: Accelerating Knowledge Distillation in LLMs. In Wanxiang Che, Joyce Nabende, Ekaterina Shutova, and Mohammad Taher Pilehvar, editors, *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers),*

pages 18085–18108, Vienna, Austria, July 2025. Association for Computational Linguistics. ISBN 979-8-89176-251-0. doi: 10.18653/v1/2025.acl-long.885. URL https://aclanthology.org/2025.acl-long.885/.

[2] Huipeng Huang and Hongxin Wei. Tail-Aware Top-k On-Policy Distillation, 2026. URL https://arxiv.org/abs/2608.14728v1. Audited version 2608.14728v1; relevant methods and experimental sections read, not reproduced. Retrieved 2026-10-28.

[3] Yaxuan Li, Yuxin Zuo, Bingxiang He, Jinqian Zhang, Chaojun Xiao, Cheng Qian, Tianyu Yu, Huan-ang Gao, Wenkai Yang, Zhiyuan Liu, and Ning Ding. Rethinking On-Policy Distillation of Large Language Models: Phenomenology, Mechanism, and Recipe, 2026. URL https://arxiv.org/abs/2604.13016v2. Audited version 2604.13016v2; relevant methods and experimental sections read, not reproduced. Retrieved 2026-10-28.

[4] Jordan Pettyjohn. IndexedLogits: indexed selected-logit CUDA implementation, 2026. URL https://github.com/pettyjohnjn/indexed_logits/tree/6020cb446cde8cb2b74a8fdf90db905a320936c3. Source inspected 2026-10-28; no project runtime reproduction.

[5] Jordan Pettyjohn. Subset-KL: subset objective implementation, 2026. URL https://github.com/pettyjohnjn/subset-kl/tree/69a813ce2233bdf243a39e7d76926ece8af76ed4. Source inspected 2026-10-28; no project runtime reproduction.

[6] Jordan Pettyjohn, Mansi Sakarvadia, Nathaniel Hudson, Daniel McKenzie, Kyle Chard, and Ian Foster. Interpreting Language Model Hidden States at Scale, 2026. URL https://arxiv.org/abs/2608.10260v1. Audited version 2608.10260v1; relevant methods and experimental sections read, not reproduced. Retrieved 2026-10-28.

[7] Rethinking OPD contributors. Current author implementation: rewards and actor update contract, 2026. URL https://github.com/Thinking-Space/Rethinking-OPD/tree/ac26e38d6f1572eb027597b48a9f4e01f6915ef8. Source inspected 2026-10-28; no project runtime reproduction.

[8] SGLang contributors. PR 38119: Add sparse per-position requested-token scoring, 2026. URL https://github.com/sgl-project/sglang/pull/38119. Source inspected 2026-10-28; no project runtime reproduction.

[9] SGLang contributors. SGLang request data structures, 2026. URL https://github.com/sgl-project/sglang/blob/4517a5ff1bbd1f944d6bde1819300ed14af7b698/python/sglang/srt/managers/io_struct.py. Source inspected 2026-10-28; no project runtime reproduction.

[10] SGLang contributors. SGLang logits processor and LM-head dispatch, 2026. URL https://github.com/sgl-project/sglang/blob/4517a5ff1bbd1f944d6bde1819300ed14af7b698/python/sglang/srt/layers/logits_processor.py. Source inspected 2026-10-28; no project runtime reproduction.

[11] SGLang contributors. SGLang input logprob processing and requested-token gather, 2026. URL https://github.com/sgl-project/sglang/blob/4517a5ff1bbd1f944d6bde1819300ed14af7b698/python/sglang/srt/layers/logprob_processor.py. Source inspected 2026-10-28; no project runtime reproduction.

[12] SGLang contributors. SGLang scoring mixin: per-item labels and score normalization, 2026. URL https://github.com/sgl-project/sglang/blob/4517a5ff1bbd1f944d6bde1819300ed14af7b698/python/sglang/srt/managers/tokenizer_manager_score_mixin.py. Source inspected 2026-10-28; no project runtime reproduction.

[13] verl contributors. Issue 6676: Student-top-k renormalized reverse-KL OPD, 2026. URL https://github.com/verl-project/verl/issues/6676. Source inspected 2026-10-28; no project runtime reproduction.

[14] verl contributors. Distillation losses: supported objective families, 2026. URL https://github.com/verl-project/verl/blob/2ab35292039a51175a4b3d3b3b2d76e951a0d3e4/verl/trainer/distillation/losses.py. Source inspected 2026-10-28; no project runtime reproduction.

[15] verl contributors. Teacher manager: inference request contract, 2026. URL https://github.com/verl-project/verl/blob/2ab35292039a51175a4b3d3b3b2d76e951a0d3e4/verl/experimental/teacher_loop/teacher_manager.py. Source inspected 2026-10-28; no project runtime reproduction.

[16] vLLM contributors. PR 56984: Per-row candidate IDs for prefill token scoring, 2026. URL https://github.com/vllm-project/vllm/pull/56984. Source inspected 2026-10-28; no project runtime reproduction.